UNIVERSIDADE ESTADUAL DE SANTA CRUZ

Mestrado em Modelagem Computacional

Projeto 1

TEORIA DA ESTIMAÇÃO

Professor: Gildson Queiroz de Jesus

Aluno: João Vitor Nascimento Ramos

Ilhéus – BA

Abril 2026

Introdução

A estimação de parâmetros e o ajuste de curvas constituem ferramentas fundamentais em Métodos Numéricos, Estatística e Modelagem Matemática, pois permitem representar relações entre variáveis observadas a partir de modelos analíticos simples. Em muitos problemas reais, os dados disponíveis apresentam dispersão e não seguem exatamente uma relação linear ou polinomial conhecida, tornando necessário utilizar técnicas de aproximação.

Neste trabalho, são estudados modelos de ajuste por mínimos quadrados aplicados a conjuntos de dados discretos. O objetivo principal é determinar funções capazes de representar adequadamente a relação entre as variáveis observadas, minimizando o erro entre os valores medidos e os valores previstos pelos modelos.

Em particular, os problemas estudados neste trabalho envolvem sistemas com maior número de equações do que incógnitas, situação típica de modelos sobredeterminados. Nesse contexto, busca-se representar os dados observados por meio da relação

$$y \approx Hx,$$

em que y representa o vetor de observações, H é a matriz de regressão e x contém os parâmetros desconhecidos do modelo. Em geral, não existe solução exata para esse sistema, pois o vetor y não pertence ao espaço coluna de H. Dessa forma, torna-se necessário determinar uma solução aproximada que minimize o erro entre os dados observados e os valores previstos pelo modelo.

Para isso, utiliza-se a formulação clássica dos mínimos quadrados, cuja solução fechada é dada por

$$\hat{x} = (H^T H)^{-1} H^T y.$$

Além da formulação livre, também será considerada sua variante restrita, na qual certas condições adicionais devem ser satisfeitas pelos parâmetros estimados. Nesses casos, emprega-se uma abordagem baseada em função penalidade, permitindo incorporar restrições ao problema original sem perder o objetivo principal de minimizar o erro de aproximação.

Modelo Epidemiológico SIR

Como primeira etapa deste trabalho, considera-se o modelo epidemiológico SIR discreto como uma forma de introduzir a análise de sistemas dinâmicos, destacando a importância da modelagem matemática na compreensão de fenômenos complexos. O modelo, originalmente desenvolvido para estudar a propagação de doenças infecciosas em uma população, divide os indivíduos em três grupos: suscetíveis, infectados e recuperados. Sua dinâmica temporal é descrita por um sistema de equações de diferenças dado por

$$S_{i+1} = S_i - \beta S_i I_i$$

$$I_{i+1} = I_i + \beta S_i I_i - \gamma I_i$$

$$R_{i+1} = R_i + \gamma I_i$$

As variáveis S_i, I_i e R_i representam, respectivamente, as frações das populações de **suscetíveis, infectados e recuperados** no instante i. Ao normalizar essas variáveis no intervalo $[0, 1]$, de modo que $S_i + I_i + R_i = 1$, o modelo permite descrever a dinâmica epidemiológica independentemente do tamanho total da população. Os parâmetros β e γ são fundamentais nesse processo: β, a taxa de infecção, mede a probabilidade de um contato entre um indivíduo suscetível e um infectado resultar em transmissão, enquanto γ, a taxa de recuperação, indica a fração de infectados que deixa esse estado por unidade de tempo.

Em geral, ambos os parâmetros variam entre 0 e 1, refletindo transições graduais. Valores próximos de zero correspondem a uma propagação e recuperação lentas, enquanto valores próximos de um indicam uma evolução acelerada do quadro. A relação entre esses coeficientes define não apenas o pico de infectados e a duração do surto, mas também demonstra a versatilidade do modelo. Sua estrutura de compartimentos e metodologia de estimação são aplicáveis analogamente a outros contextos de sistemas complexos, como a difusão de tecnologias, informações ou comportamentos em cenários econômicos e sociais, reforçando a importância da análise quantitativa em diversas áreas do conhecimento.

Simulação do Modelo

Para a análise da dinâmica do sistema, o modelo *SIR* foi simulado no intervalo discreto $i = 0, \ldots, 350$, com condições iniciais definidas por

$$S_0 = 0.9, \quad I_0 = 0.1, \quad R_0 = 0,$$

e parâmetros

$$\beta = 0.9, \quad \gamma = 0.1429.$$

Nesta configuração, as populações são tratadas de forma relativa, variando no intervalo $[0, 1]$, o que permite acompanhar a evolução das frações de cada compartimento independentemente do tamanho total do grupo estudado.

O horizonte temporal de 350 passos é utilizado de forma ilustrativa para observar a estabilização completa do sistema, podendo cada passo representar diferentes unidades de tempo (dias, semanas ou meses), dependendo do fenômeno modelado. É importante notar que o parâmetro γ possui uma interpretação temporal direta: o valor $0.1429 \approx 1/7$ indica que o tempo médio de permanência de um indivíduo no compartimento de infectados é de 7 unidades de tempo. Se considerarmos cada passo i como um dia, o modelo descreve uma patologia com período de recuperação médio de uma semana.

Como mostrado na Figura 1, o sistema atinge um estado de equilíbrio estável a longo prazo, em que a curva de infectados retorna a zero e a população de recuperados atinge seu platô máximo.

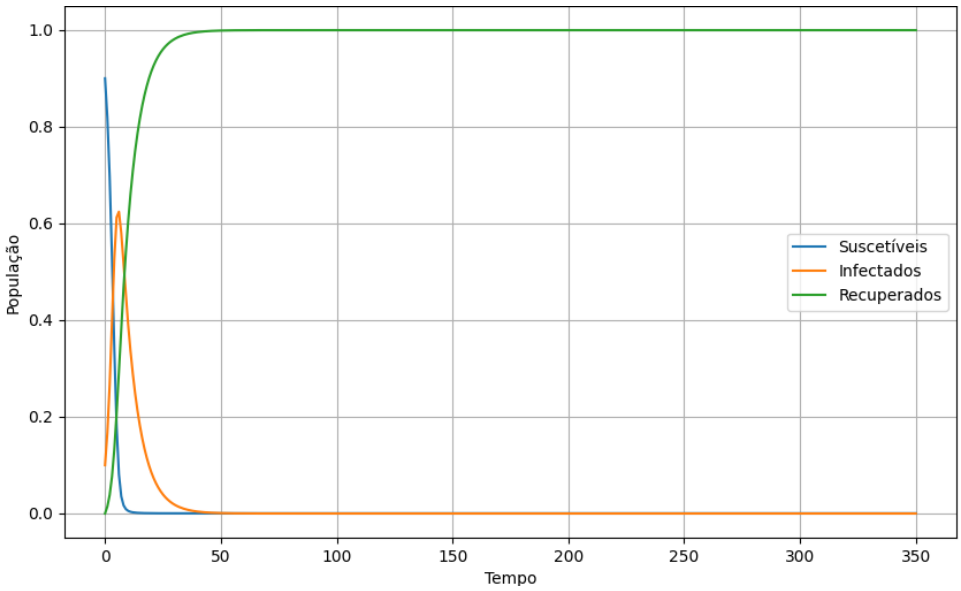

Figura 1: Evolução temporal das populações S_i, I_i e R_i ao longo de 350 passos. Observa-se a estabilização do sistema e o comportamento assintótico das frações de cada compartimento.

Para uma compreensão mais detalhada da fase crítica de transição, realizou-se um recorte focado nos primeiros 50 passos temporais. Este ajuste de escala é fundamental, pois é neste intervalo que ocorre a dinâmica principal: o crescimento acentuado da infecção, o atingimento do pico do surto (em torno do passo 6) e o início do declínio da curva I_i, como evidenciado na Figura 2.

Essa transição reflete diretamente a escala de tempo de uma semana estabelecida para a recuperação ($\gamma \approx 1/7$). No gráfico, observa-se que o declínio da curva de infectados e a ascensão mais acentuada da curva de recuperados ocorrem de forma defasada em relação ao início do surto, respeitando o período médio em que os indivíduos permanecem no compartimento I_i. A rapidez com que o sistema atinge o pico e inicia a estabilização demonstra a alta taxa de transmissibilidade ($\beta = 0.9$) em contraste com o tempo de permanência no estado infeccioso.

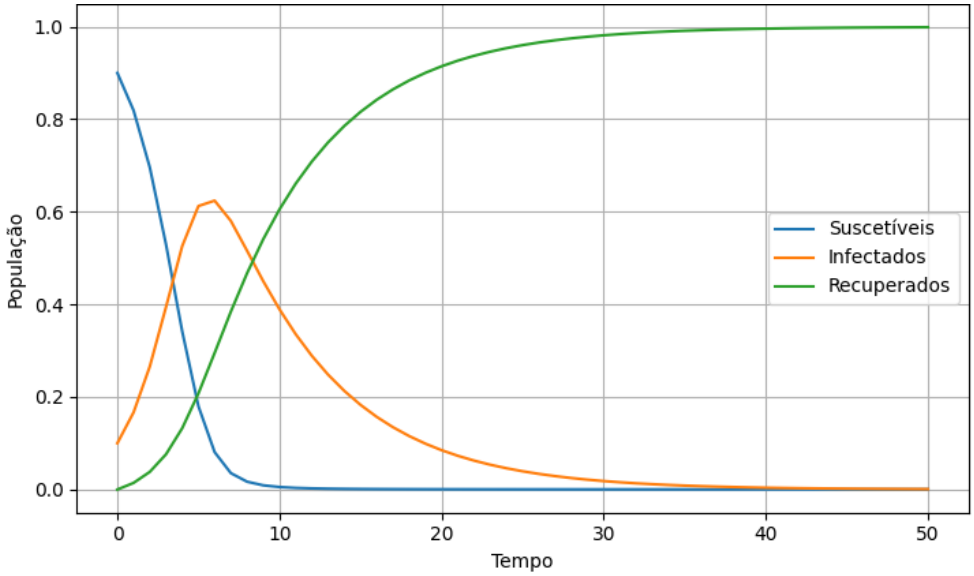

Figura 2: Detalhe da evolução das populações nos primeiros 50 passos, destacando a fase de crescimento rápido da infecção e o pico do surto.

Estimativa dos Parâmetros $\hat{\beta}$ e $\hat{\gamma}$

Com as trajetórias simuladas S_i, I_i e R_i obtidas na seção anterior, podemos estimar os parâmetros do modelo SIR discreto utilizando o método dos mínimos quadrados. O objetivo é encontrar $\hat{\beta}$ e $\hat{\gamma}$ que melhor reproduzam as diferenças observadas entre os passos consecutivos das populações.

Inicialmente reescrevemos as equações do modelo isolando os termos lineares em β e γ.

Estimando β

Para β Começamos a partir da equação dos suscetíveis:

$$S_{k+1} = S_k - \beta S_k I_k.$$

Passando β para o outro lado, obtemos:

$$S_k - S_{k+1} = \beta S_k I_k.$$

Neste ponto, para cada instante k, conhecemos S_k, S_{k+1} e I_k. Definimos então:

$$y_k = S_k - S_{k+1}, \quad x_k = S_k I_k,$$

de modo que o problema se reduz a um ajuste linear simples passando pela origem:

$$y_k = \beta x_k.$$

De forma geral, o método dos **mínimos quadrados** busca o valor $\hat{\beta}$ que minimiza a soma dos quadrados dos resíduos:

$$\min_{\beta} \sum_{k=0}^{N-1} (y_k - \beta x_k)^2.$$

Essa formulação pode ser expressa na notação matricial clássica de mínimos quadrados. Definimos:

$$H = \begin{bmatrix} x_0 \\ x_1 \\ \vdots \\ x_{N-1} \end{bmatrix}, \quad y = \begin{bmatrix} y_0 \\ y_1 \\ \vdots \\ y_{N-1} \end{bmatrix}, \quad \hat{x} = \begin{bmatrix} \hat{\beta} \end{bmatrix}.$$

O problema de mínimos quadrados é então:

$$H^\top H \hat{x} = H^\top y,$$

cuja solução analítica fornece:

$$\hat{\beta} = (H^\top H)^{-1} H^\top y = \frac{\sum_{k=0}^{N-1} x_k y_k}{\sum_{k=0}^{N-1} x_k^2}.$$

Substituindo $x_k = S_k I_k$ e $y_k = S_k - S_{k+1}$, obtemos:

$$\hat{\beta} = \frac{\sum_{k=0}^{N-1} (S_k I_k)(S_k - S_{k+1})}{\sum_{k=0}^{N-1} (S_k I_k)^2}.$$

Estimando γ

De forma análoga, para γ utilizamos a equação dos recuperados:

$$R_{k+1} = R_k + \gamma I_k,$$

que reorganizada fica:

$$R_{k+1} - R_k = \gamma I_k.$$

Definindo:

$$y_k = R_{k+1} - R_k, \quad x_k = I_k,$$

temos novamente um ajuste linear simples passando pela origem:

$$y_k = \gamma x_k.$$

Na forma matricial:

$$H = \begin{bmatrix} x_0 \\ x_1 \\ \vdots \\ x_{N-1} \end{bmatrix}, \quad y = \begin{bmatrix} y_0 \\ y_1 \\ \vdots \\ y_{N-1} \end{bmatrix}, \quad \hat{x} = \begin{bmatrix} \hat{\gamma} \end{bmatrix},$$

e a solução por mínimos quadrados é:

$$\hat{x} = \hat{\gamma} = (H^\top H)^{-1} H^\top y = \frac{\sum_{k=0}^{N-1} I_k (R_{k+1} - R_k)}{\sum_{k=0}^{N-1} I_k^2}.$$

Portanto, teoricamente a estimação dos parâmetros β e γ se reduz a dois ajustes lineares simples passando pela origem, que são casos particulares da formulação matricial clássica de mínimos quadrados. Essa abordagem conecta elegantemente a interpretação didática do modelo SIR com a fundamentação matemática rigorosa do método de estimação.

Resultados e Análise Analítica

A estimação dos parâmetros via mínimos quadrados recuperou precisamente os valores originais utilizados na simulação:

- $\hat{\beta} = 0.9000$
- $\hat{\gamma} = 0.1429$

Do ponto de vista analítico, esse resultado é esperado, uma vez que a simulação é estritamente **determinística**. Como não foi introduzido nenhum ruído estocástico nem erros de medição, os dados simulados (y) seguem exatamente as combinações lineares definidas pela matriz de regressores (H). Nesse contexto, o método de mínimos quadrados consegue recuperar os parâmetros teóricos de forma exata, ilustrando a consistência do procedimento de estimação em cenários ideais.

Experimento com Conjunto de Dados Reduzido

Para avaliar a robustez da estimação via mínimos quadrados, realizamos um experimento utilizando apenas uma **subamostra dos dados simulados**. Selecionamos os **índices pares** do conjunto original, ou seja, $k = 0, 2, 4, \ldots, 348$, correspondendo a aproximadamente metade das observações disponíveis.

Aplicando o mesmo procedimento descrito na seção anterior, obtivemos os seguintes parâmetros estimados:

- $\hat{\beta}_{\text{reduzido}} = 1.7367$
- $\hat{\gamma}_{\text{reduzido}} = 0.2835$

Observa-se que os valores estimados são aproximadamente o **dobro dos parâmetros originais** ($\beta = 0.9$ e $\gamma = 0.1429$). Analiticamente, isso ocorre porque a redução do conjunto de dados aumenta o **espaçamento temporal entre as observações**: cada passo na subamostra reduzida acumula aproximadamente dois passos do modelo original.

Matematicamente, considerando pequenas variações entre passos consecutivos, temos:

$$S_{k+2} - S_k \approx (S_{k+1} - S_k) + (S_{k+2} - S_{k+1}) \approx 2\beta S_k I_k,$$

$$R_{k+2} - R_k \approx 2\gamma I_k.$$

Ao aplicar o ajuste linear $y = \beta x$ ou $y = \gamma x$ nos dados espaçados de dois em dois, o método interpreta essa **diferença dobrada** como um coeficiente maior, resultando em $\hat{\beta}_{\text{reduzido}} \approx 2\beta$ e $\hat{\gamma}_{\text{reduzido}} \approx 2\gamma$. Esse experimento evidencia que, embora o método de mínimos quadrados seja consistente em cenários determinísticos completos, a **densidade**

e o espaçamento dos dados desempenham papel crucial na interpretação quantitativa dos parâmetros.

O resultado mais notável é que, ao simular o modelo SIR com os parâmetros ajustados $(\hat{\beta}_{\text{reduzido}}/2, \hat{\gamma}_{\text{reduzido}}/2)$ e passo unitário $(i = 0, 1, 2, \ldots)$, as trajetórias **preservam a tendência geral da dinâmica populacional**, reproduzindo de forma fiel o crescimento inicial, o pico e o declínio das curvas, como ilustrado na Figura 3.

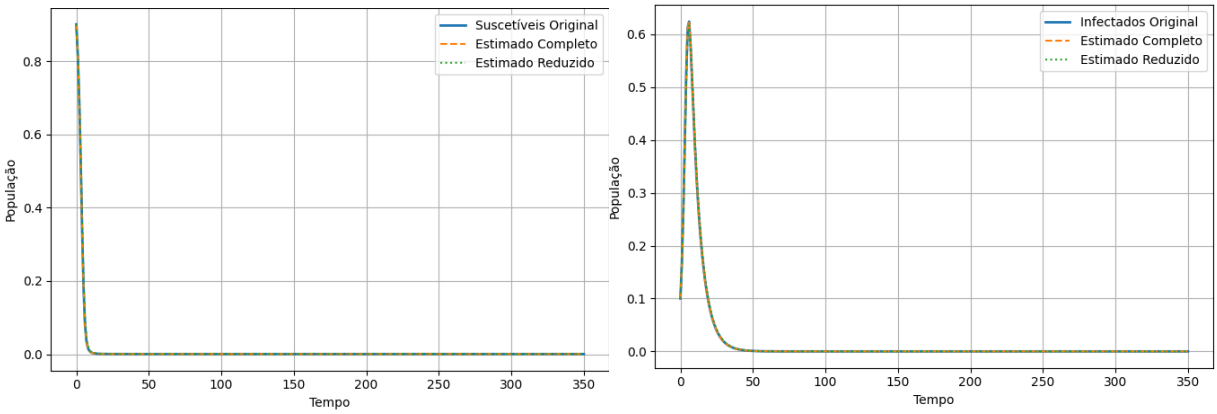

(a) Suscetíveis

(b) Infectados

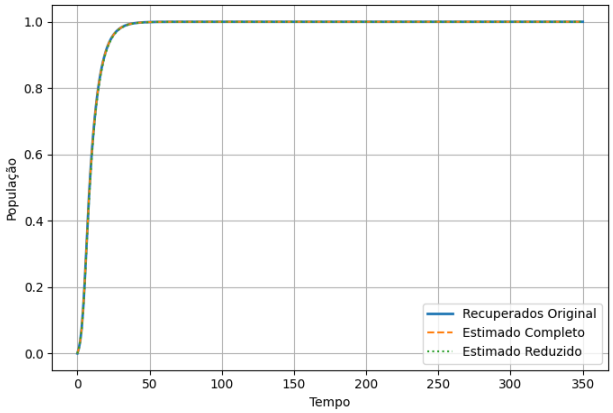

(c) Recuperados

Figura 3: Comparação da reconstrução das populações S_i, I_i e R_i. As linhas tracejadas (laranja e verde) representam a simulação utilizando os parâmetros estimados via dados completos e dados reduzidos, respectivamente, demonstrando que a tendência geral das curvas é preservada em relação à simulação original (azul).

Análise dos Erros

Apesar da convergência visual das trajetórias, a reconstrução com dados reduzidos apresenta pequenas diferenças em relação à simulação original. Como mostrado na Figura 4, o erro absoluto apresenta picos entre aproximadamente 0.015 e 0.025 durante as regiões de transição mais rápida, especialmente próximas ao crescimento dos infectados e à queda dos suscetíveis. Após essas transições, o erro tende gradualmente a zero.

Optou-se por utilizar erro absoluto em vez de erro relativo porque, no modelo SIR,

algumas populações podem assumir valores muito próximos de zero ao longo da simulação. Nessas situações, o erro relativo tende a crescer artificialmente, pois pequenas diferenças absolutas passam a ser divididas por valores muito pequenos, produzindo picos exagerados e pouco representativos.

Assim, o erro absoluto fornece uma medida mais estável e interpretável da diferença entre as trajetórias. Os resultados mostram que, mesmo com amostragem reduzida, as discrepâncias permanecem pequenas, indicando que a dinâmica principal do modelo foi preservada.

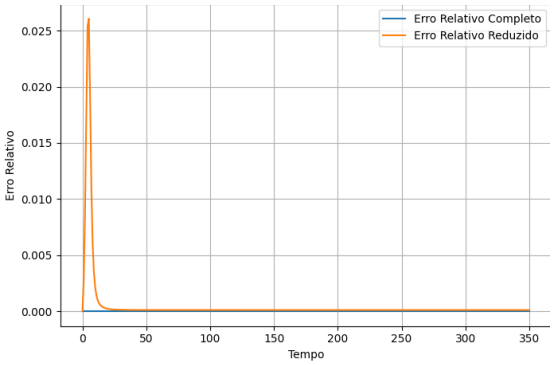

(a) Erro S_i

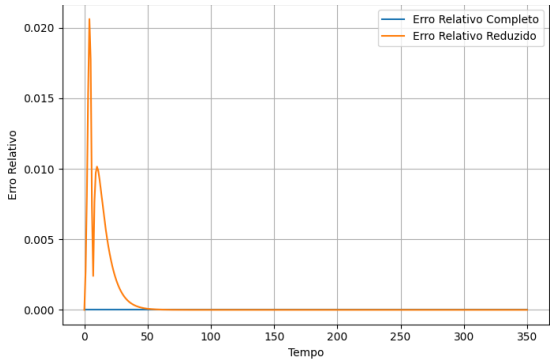

(b) Erro I_i

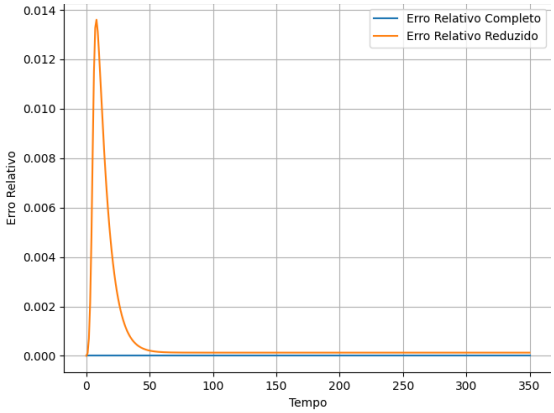

(c) Erro R_i

Figura 4: Evolução do erro absoluto entre a simulação original e a reconstrução com dados reduzidos.

Ajuste de Curvas via Mínimos Quadrados: Renda e Consumo

Neste momento, aplicamos a técnica para ajustar curvas lineares e quadráticas aos dados de Renda (x) e Consumo (y), ilustrando sua utilidade em problemas econômicos reais.

A compreensão de como renda e consumo se relacionam é crucial para estudos de comportamento do consumidor, formulação de políticas econômicas e previsão de demanda. O ajuste de curvas via mínimos quadrados permite estimar funções que representam a tendência média dos dados, detectar não linearidades e avaliar a dispersão em torno da relação prevista, fornecendo bases sólidas para decisões analíticas.

Tabela de Dados: Renda vs. Consumo

A Tabela 1 apresenta os valores observados de Renda e Consumo que serão utilizados para os ajustes. Esses dados permitem aplicar tanto modelos lineares, quando se presume uma relação proporcional direta, quanto modelos quadráticos, que capturam possíveis curvaturas e efeitos não lineares na relação entre renda e consumo.

Renda (x)	**Consumo** (y)
139	122
126	114
90	86
144	134
163	146
136	107
61	68
62	117
41	71
120	98

Tabela 1: Dados utilizados para o ajuste de curvas via Mínimos Quadrados.

O estudo desse ajuste não se restringe à economia: a metodologia aqui apresentada é amplamente aplicável em engenharia, ciências sociais, biologia e qualquer área em que seja necessário modelar dados observacionais e prever tendências.

Formulação do Ajuste via Mínimos Quadrados

Ajuste Linear

Para o ajuste linear, buscamos uma função da forma:

$$y = a_0 + a_1 x$$

onde os coeficientes a_0 e a_1 são determinados pelo método dos mínimos quadrados, que minimiza a soma dos quadrados dos resíduos:

$$\min_{a_0,a_1} \sum_{i=1}^{n} \left(y_i - (a_0 + a_1 x_i)\right)^2 .$$

Em termos matriciais. O ajuste pode ser expresso na forma padrão:

$$H^T H \hat{x} = H^T y \quad \Rightarrow \quad \hat{x} = (H^T H)^{-1} H^T y,$$

onde H é a matriz de regressores, y é o vetor de observações e $\hat{x}$ contém os coeficientes estimados.

Para o modelo linear $y = a_0 + a_1 x$, a matriz H_{linear} e o vetor y são:

$$H_{\text{linear}} = \begin{bmatrix} 1 & 139 \\ 1 & 126 \\ 1 & 90 \\ 1 & 144 \\ 1 & 163 \\ 1 & 136 \\ 1 & 61 \\ 1 & 62 \\ 1 & 41 \\ 1 & 120 \end{bmatrix}, \quad y = \begin{bmatrix} 122 \\ 114 \\ 86 \\ 134 \\ 146 \\ 107 \\ 68 \\ 117 \\ 71 \\ 98 \end{bmatrix}.$$

A aplicação da fórmula $\hat{x} = (H^T H)^{-1} H^T y$ fornece os coeficientes estimados:

$$\hat{x}_{\text{linear}} = \begin{bmatrix} a_0 \\ a_1 \end{bmatrix} = \begin{bmatrix} 52.6930 \\ 0.4954 \end{bmatrix}.$$

Portanto, a curva ajustada é:

$$\hat{y}_{\text{linear}} = 52.6930 + 0.4954\, x.$$

Ajuste Quadrático

Para o ajuste quadrático, consideramos:

$$y = b_0 + b_1 x + b_2 x^2,$$

com os coeficientes b_0, b_1 e b_2 determinados da mesma forma, minimizando:

$$\min_{b_0,b_1,b_2} \sum_{i=1}^{n} \left(y_i - (b_0 + b_1 x_i + b_2 x_i^2)\right)^2 .$$

Ao aplicarmos a formulação padrão do método dos mínimos quadrados, temos a matriz de regressores:

$$H_{\text{quadratico}} = \begin{bmatrix} 1 & 139 & 19321 \\ 1 & 126 & 15876 \\ 1 & 90 & 8100 \\ 1 & 144 & 20736 \\ 1 & 163 & 26569 \\ 1 & 136 & 18496 \\ 1 & 61 & 3721 \\ 1 & 62 & 3844 \\ 1 & 41 & 1681 \\ 1 & 120 & 14400 \end{bmatrix} .$$

Aplicando a fórmula dos mínimos quadrados, obtemos os coeficientes:

$$\hat{x}_{\text{quadratico}} = \begin{bmatrix} b_0 \\ b_1 \\ b_2 \end{bmatrix} = \begin{bmatrix} 91.6270 \\ -0.4297 \\ 0.0046 \end{bmatrix} .$$

definindo a parábola ajustada:

$$\hat{y}_{\text{quadratico}} = 91.6270 - 0.4297\, x + 0.0046\, x^2.$$

Análise Gráfica e Estudo de Erros

Nesta seção, comparamos o desempenho dos modelos linear e quadrático por meio da visualização das curvas ajustadas sobre os dados reais (Figura 5) e da análise quantitativa dos erros residuais.

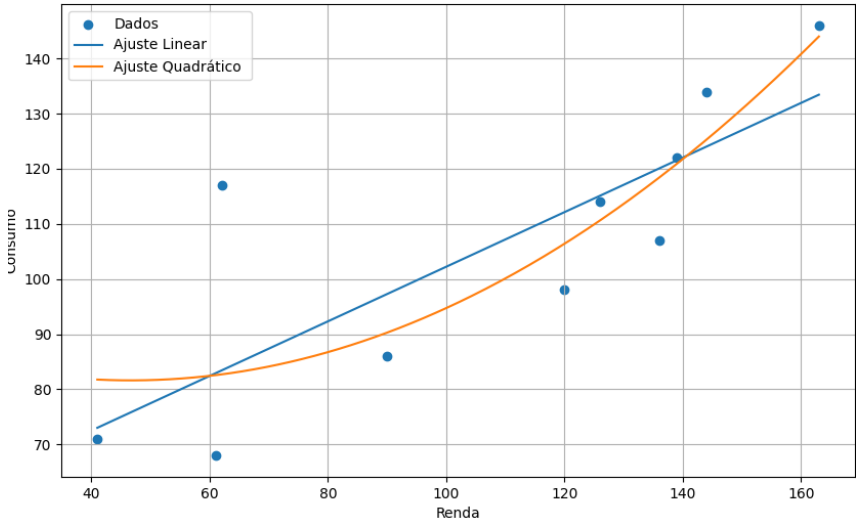

Figura 5: Ajustes linear e quadrático aos dados de Renda vs. Consumo.

A análise gráfica evidencia que os dados apresentam dispersão considerável, especialmente na faixa intermediária de renda. Apesar disso, o modelo quadrático apresenta desempenho superior, refletido em um RMSE de 13.4753, inferior ao RMSE de 14.5302 obtido pelo ajuste linear.

Ponto	**Renda (x)**	**Erro Relativo (Linear)**	**Erro Relativo (Quadrático)**
1	139	0.0036	0.0088
2	126	0.0098	0.0295
3	90	0.1312	0.0497
4	144	0.0744	0.0649
5	163	0.0860	0.0136
6	136	0.1222	0.1067
7	61	0.2193	0.2141
8	62	0.2871	0.2932
9	41	0.0283	0.1515
10	120	0.1443	0.0859
RMSE	-	**14.5302**	**13.4753**

Tabela 2: Erro relativo ponto a ponto e RMSE para os ajustes linear e quadrático, com indicação da renda correspondente a cada observação.

Observa-se que o erro relativo atinge valores elevados nos pontos 7 e 8 em ambos os modelos, indicando a presença de *outliers* ou a influência de fatores adicionais sobre o consumo que não são explicados apenas pela renda. A melhoria do ajuste quadrático justifica a inclusão do parâmetro adicional, permitindo capturar melhor a curvatura e a tendência não linear presente nos dados de consumo.

Estudo do Ajuste com Restrição de Igualdade

O princípio central do ajuste restrito é determinar os coeficientes que minimizam o erro quadrático total, enquanto satisfazem simultaneamente uma condição específica. No caso estudado, a condição é que a curva ajustada passe exatamente pelo ponto $(x_r, y_r) = (163, 146)$.

Matematicamente, esse problema é resolvido utilizando o *Método dos Multiplicadores de Lagrange*. O sistema de equações normais do método dos mínimos quadrados,

$$\mathbf{H}^T\mathbf{H}\hat{x} = \mathbf{H}^T y,$$

é expandido para incluir a restrição $G\hat{x} = u$, resultando no seguinte sistema linear aumentado:

$$\begin{bmatrix} \mathbf{H}^T\mathbf{H} & G^T \\ G & 0 \end{bmatrix} \begin{bmatrix} \hat{x} \\ \lambda \end{bmatrix} = \begin{bmatrix} \mathbf{H}^T y \\ u \end{bmatrix},$$

onde G representa a avaliação da base do modelo no ponto restrito e u é o valor alvo da restrição (146). O vetor λ corresponde aos multiplicadores de Lagrange, que garantem a satisfação da condição.

Implementação nos Modelos

Ajuste Linear Restrito

Para o modelo $y = a_0 + a_1 x$, a restrição impõe:

$$a_0 + a_1 \cdot 163 = 146.$$

Vetor de Restrição: $G = \begin{bmatrix} 1 & 163 \end{bmatrix}$.

Ajuste Quadrático Restrito

Para o modelo $y = b_0 + b_1 x + b_2 x^2$, a restrição impõe:

$$b_0 + b_1 \cdot 163 + b_2 \cdot 163^2 = 146.$$

Vetor de Restrição: $G = \begin{bmatrix} 1 & 163 & 163^2 \end{bmatrix}$.

Após a aplicação do método com restrição de igualdade, obtivemos os seguintes modelos ajustados:

$$\hat{y}_{\text{linear}} = 0.6459\,x + 40.7145$$

$$\hat{y}_{\text{quadrático}} = 0.0051\,x^2 - 0.5176\,x + 94.9366$$

Análise dos Resultados

A Tabela 3 resume os erros relativos ponto a ponto e o RMSE para cada modelo restrito. Nota-se que o Ponto 5 ($x = 163$) apresenta erro nulo, confirmando que a restrição foi aplicada corretamente.

Ponto	Erro Relativo (Linear)	Erro Relativo (Quadrático)
1	0.0697	0.0043
2	0.0711	0.0294
3	0.1494	0.0423
4	0.0020	0.0589
5	**0.0000**	**0.0000**
6	0.2015	0.1105
7	0.1782	0.2107
8	0.3097	0.2954
9	0.0536	0.1589
10	0.2064	0.0840
RMSE	16.2829	13.4973

Tabela 3: Erros relativos ponto a ponto e RMSE para os ajustes linear e quadrático restritos ao ponto $(163, 146)$.

Comparando os ajustes restritos com os ajustes sem restrição, observa-se que o RMSE do modelo linear aumentou de 14.53 para 16.28, indicando que a reta precisou "incliná-la"para atender à restrição, comprometendo o ajuste de alguns pontos intermediários. Por outro lado, o ajuste quadrático manteve praticamente o mesmo RMSE (13.49 versus 13.4973), demonstrando que o modelo possui flexibilidade suficiente para absorver a restrição sem alterar significativamente a qualidade do ajuste.

Na Figura 6, é possível observar visualmente como a reta linear se ajusta para tocar o ponto restrito, enquanto a parábola quadrática consegue atender à restrição sem distorcer a tendência geral do ajuste.

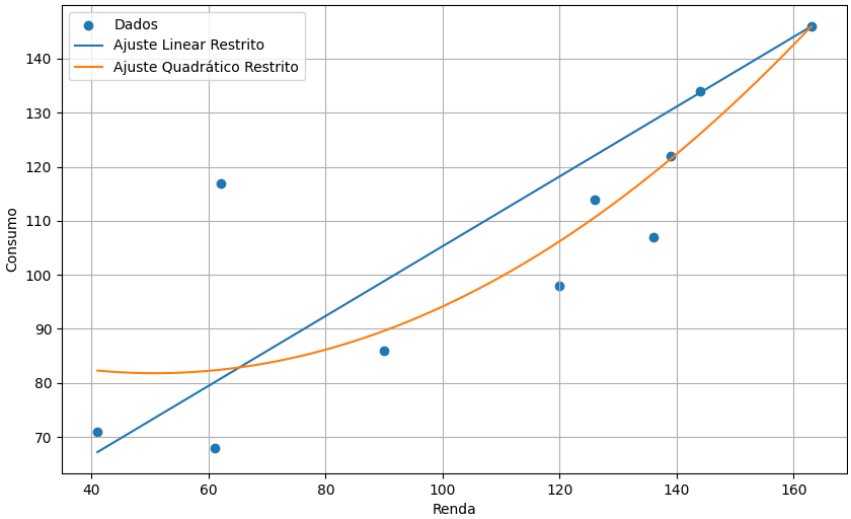

Figura 6: Ajustes linear e quadrático restritos ao ponto $(163, 146)$.

Conclusão

Neste trabalho, foram aplicados métodos numéricos em dois contextos distintos: modelagem epidemiológica e ajuste de curvas. Na primeira parte, o modelo SIR discreto permitiu representar a evolução das populações suscetíveis, infectadas e recuperadas ao longo do tempo. Além disso, a estimação dos parâmetros β e γ por mínimos quadrados apresentou resultados consistentes, recuperando valores muito próximos daqueles utilizados na simulação original.

Também foi analisado o impacto da redução dos dados disponíveis para estimação. Mesmo utilizando apenas parte da série temporal, o modelo reconstruído preservou a dinâmica principal do sistema, apresentando diferenças pequenas em termos absolutos.

Na segunda parte, foram estudados modelos de regressão linear, quadrática e com restrição de igualdade para descrever a relação entre renda e consumo. Os resultados mostraram que os modelos ajustados conseguiram representar adequadamente a tendência dos dados, enquanto a restrição permitiu incorporar uma condição adicional sem comprometer a coerência global do ajuste.

De forma geral, o trabalho evidenciou a utilidade dos métodos numéricos na construção de modelos capazes de descrever, interpretar e prever fenômenos reais a partir de dados observados.