UNIVERSIDADE ESTADUAL DE SANTA CRUZ

Mestrado em Modelagem Computacional

Projeto 1

TEORIA DA ESTIMAÇÃO

Professor: Gildson Queiroz de Jesus

Aluno: João Vitor Nascimento Ramos

Ilhéus – BA

Abril 2026

Introdução

A estimação de parâmetros e o ajuste de curvas são ferramentas centrais em Métodos Numéricos, Estatística e Modelagem Matemática, pois viabilizam a representação de relações entre variáveis observadas por meio de modelos analíticos. Na prática, entretanto, os dados experimentais frequentemente apresentam dispersão e não se ajustam de forma exata a modelos lineares ou polinomiais previamente definidos. Diante disso, torna-se necessário empregar técnicas de aproximação que permitam obter representações adequadas do comportamento observado, ainda que de forma aproximada.

Neste estudo, são analisados modelos de ajuste por mínimos quadrados aplicados a conjuntos de dados discretos, com o objetivo de determinar funções capazes de representar adequadamente a relação entre as variáveis observadas, minimizando o erro entre os valores medidos e aqueles previstos pelos modelos. A abordagem concentra-se em situações em que o número de equações excede o de incógnitas, caracterizando sistemas sobredeterminados, nos quais a representação dos dados é formulada por meio de uma relação matricial, permitindo a obtenção de soluções aproximadas que melhor se ajustam ao conjunto observado. Nesse contexto, os dados observados são representados pela relação

$$y \approx Hx \tag{1}$$

em que y denota o vetor de observações, H corresponde à matriz de regressão e x reúne os parâmetros desconhecidos do modelo. Como, em geral, o sistema é sobredeterminado, não há solução exata que satisfaça essa igualdade, uma vez que y não pertence ao espaço coluna de H. Assim, busca-se uma solução aproximada que melhor ajuste os dados, minimizando o erro entre os valores observados e aqueles estimados pelo modelo. Para esse fim, emprega-se a formulação clássica dos mínimos quadrados, cuja solução em forma fechada é dada por

$$\hat{x} = (H^T H)^{-1} H^T y \tag{2}$$

Além da formulação livre, considera-se também sua variante restrita, na qual os parâmetros estimados devem satisfazer condições adicionais, sendo adotada uma abordagem por função penalidade para incorporar tais restrições sem comprometer a minimização do erro de aproximação.

Modelo Epidemiológico SIR

Como primeira etapa deste estudo, considera-se o modelo epidemiológico SIR discreto como uma forma de introduzir a análise de sistemas dinâmicos, evidenciando o papel da modelagem matemática na compreensão de fenômenos complexos. Esse modelo, originalmente proposto para descrever a propagação de doenças infecciosas, divide a população em três grupos: suscetíveis, infectados e recuperados. Sua dinâmica temporal é descrita pelo seguinte sistema de equações:

$$S_{i+1} = S_i - \beta S_i I_i \tag{3}$$

$$I_{i+1} = I_i + \beta S_i I_i - \gamma I_i \tag{4}$$

$$R_{i+1} = R_i + \gamma I_i \tag{5}$$

As variáveis S_i, I_i e R_i representam, respectivamente, as frações das populações de **suscetíveis, infectados e recuperados** no instante i. Ao normalizá-las no intervalo $[0, 1]$, de modo que $S_i + I_i + R_i = 1$, o modelo passa a descrever a dinâmica epidemiológica de forma independente do tamanho total da população. Os parâmetros β e γ desempenham papel central nesse processo: β representa a taxa de infecção, associada à probabilidade de transmissão em um contato entre indivíduos suscetíveis e infectados, enquanto γ corresponde à taxa de recuperação, indicando a fração de indivíduos que deixam o estado infeccioso por unidade de tempo.

Em geral, ambos os parâmetros assumem valores entre 0 e 1, refletindo a natureza gradual das transições. Valores reduzidos estão associados a uma evolução mais lenta da dinâmica, ao passo que valores elevados indicam propagação e recuperação mais rápidas. A relação entre esses coeficientes influencia diretamente o comportamento do sistema, determinando o pico de infectados e a duração do surto, além de evidenciar a flexibilidade do modelo. Essa mesma estrutura pode ser empregada, de forma análoga, na análise de outros sistemas complexos, como a difusão de informações, tecnologias ou comportamentos em contextos sociais e econômicos.

Simulação do Modelo

Para analisar a dinâmica do sistema, o modelo *SIR* foi simulado no intervalo discreto $i = 0, \ldots, 350$, considerando as condições iniciais

$$S_0 = 0.9, \quad I_0 = 0.1, \quad R_0 = 0,$$

e os parâmetros

$$\beta = 0.9, \quad \gamma = 0.1429.$$

Nessa configuração, as variáveis são tratadas de forma normalizada no intervalo $[0, 1]$, permitindo acompanhar a evolução das frações de cada compartimento independentemente do tamanho total da população.

O horizonte temporal de 350 passos é adotado com caráter ilustrativo, permitindo observar a estabilização do sistema ao longo do tempo. Cada passo pode representar diferentes unidades temporais (dias, semanas ou meses), a depender do fenômeno modelado. Destaca-se que o parâmetro γ possui interpretação temporal direta: o valor $0.1429 \approx 1/7$ indica que o tempo médio de permanência de um indivíduo no compartimento de infectados é de aproximadamente 7 unidades de tempo. Assim, ao considerar cada passo i como um dia, o modelo passa a representar uma doença com período médio de recuperação de cerca de uma semana.

Como ilustrado na Figura 1, o sistema converge para um estado de equilíbrio estável no longo prazo, no qual a fração de infectados tende a zero, enquanto a população de recuperados atinge um valor máximo constante.

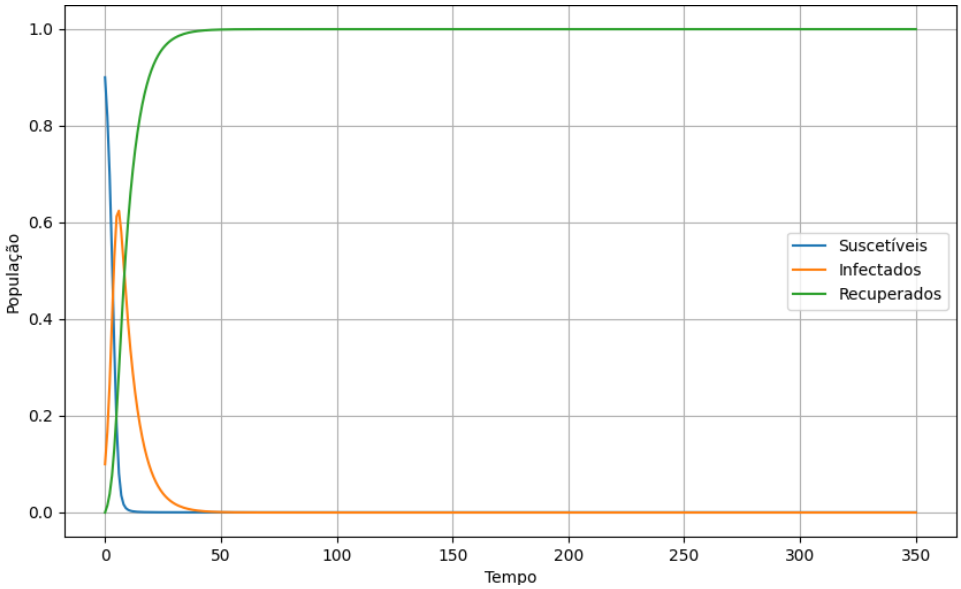

Figura 1: Evolução temporal das populações S_i, I_i e R_i ao longo de 350 passos.

Para uma análise mais detalhada da fase crítica do sistema, considera-se um recorte nos primeiros 50 passos temporais, intervalo no qual se concentra a dinâmica mais significativa do modelo. Nesse período, observa-se o crescimento acentuado da infecção, o atingimento do pico do surto (em torno do passo 6) e o início do declínio da curva I_i, conforme ilustrado na Figura 2.

Essa transição está diretamente associada à escala temporal definida pelo parâmetro de recuperação ($\gamma \approx 1/7$). Nota-se que a redução da curva de infectados e o aumento mais pronunciado da curva de recuperados ocorrem de forma defasada em relação ao início do surto, refletindo o tempo médio de permanência dos indivíduos no compartimento I_i. Além disso, a rapidez com que o sistema atinge o pico e inicia o processo de estabilização evidencia a elevada taxa de transmissibilidade ($\beta = 0.9$) em relação ao tempo de recuperação.

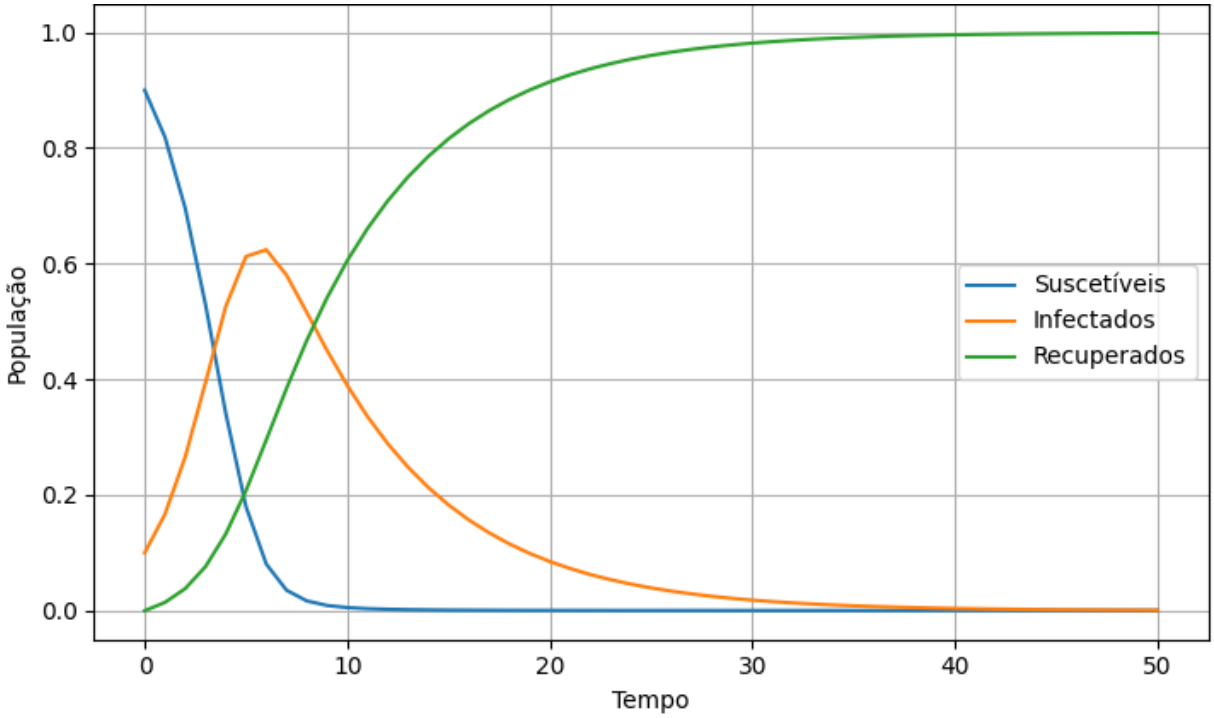

Figura 2: Detalhe da evolução das populações nos primeiros 50 passos, destacando a fase de crescimento rápido da infecção e o pico do surto.

Estimativa dos Parâmetros $\hat{\beta}$ e $\hat{\gamma}$

Com base nas trajetórias simuladas S_i, I_i e R_i obtidas na seção anterior, procede-se à estimação dos parâmetros do modelo SIR discreto por meio do método dos mínimos quadrados. O objetivo é determinar os valores de $\hat{\beta}$ e $\hat{\gamma}$ que melhor reproduzam as variações observadas entre instantes consecutivos das populações.

Para isso, reescrevem-se as equações do modelo de forma a explicitar a dependência linear em relação aos parâmetros.

Estimativa de β

Parte-se da equação que descreve a dinâmica dos suscetíveis:

$$S_{k+1} = S_k - \beta S_k I_k \tag{6}$$

Reorganizando os termos, obtém-se:

$$S_k - S_{k+1} = \beta S_k I_k \tag{7}$$

Como, para cada instante k, são conhecidos os valores de S_k, S_{k+1} e I_k, definem-se:

$$y_k = S_k - S_{k+1}, \tag{8}$$

$$x_k = S_k I_k. \tag{9}$$

O modelo linear resultante é dado por:

$$y_k = \beta x_k. \tag{10}$$

O método dos **mínimos quadrados** consiste em determinar o valor de $\hat{\beta}$ que minimiza a soma dos quadrados dos resíduos:

$$\min_{\beta} \sum_{k=0}^{N-1} (y_k - \beta x_k)^2. \tag{11}$$

Essa formulação pode ser expressa na forma matricial clássica. Define-se:

$$H = \begin{bmatrix} x_0 \\ x_1 \\ \vdots \\ x_{N-1} \end{bmatrix}, \quad y = \begin{bmatrix} y_0 \\ y_1 \\ \vdots \\ y_{N-1} \end{bmatrix}, \quad \hat{x} = \begin{bmatrix} \hat{\beta} \end{bmatrix}. \tag{12}$$

O problema de mínimos quadrados leva às equações normais:

$$H^\top H\hat{x} = H^\top y, \tag{13}$$

cuja solução analítica é dada por:

$$\hat{\beta} = (H^\top H)^{-1} H^\top y = \frac{\sum_{k=0}^{N-1} x_k y_k}{\sum_{k=0}^{N-1} x_k^2}. \tag{14}$$

Por fim, substituindo $x_k = S_k I_k$ e $y_k = S_k - S_{k+1}$, obtém-se:

$$\hat{\beta} = \frac{\sum_{k=0}^{N-1} (S_k I_k)(S_k - S_{k+1})}{\sum_{k=0}^{N-1} (S_k I_k)^2}. \tag{15}$$

Estimativa de γ

De forma análoga, utiliza-se a equação que descreve a dinâmica dos recuperados:

$$R_{k+1} = R_k + \gamma I_k. \tag{16}$$

Reorganizando os termos, obtém-se:

$$R_{k+1} - R_k = \gamma I_k. \tag{17}$$

Definem-se então as variáveis:

$$y_k = R_{k+1} - R_k, \tag{18}$$

$$x_k = I_k, \tag{19}$$

o que conduz ao modelo linear:

$$y_k = \gamma x_k. \tag{20}$$

Na forma matricial, define-se:

$$H = \begin{bmatrix} x_0 \\ x_1 \\ \vdots \\ x_{N-1} \end{bmatrix}, \quad y = \begin{bmatrix} y_0 \\ y_1 \\ \vdots \\ y_{N-1} \end{bmatrix}, \quad \hat{x} = \begin{bmatrix} \hat{\gamma} \end{bmatrix}. \tag{21}$$

A solução por mínimos quadrados é então dada por:

$$\hat{\gamma} = (H^\top H)^{-1} H^\top y = \frac{\sum_{k=0}^{N-1} I_k (R_{k+1} - R_k)}{\sum_{k=0}^{N-1} I_k^2}. \tag{22}$$

Dessa forma, a estimação de β e γ reduz-se a dois ajustes lineares simples passando pela origem, constituindo casos particulares da formulação clássica de mínimos quadrados.

Resultados e Análise Analítica

A estimação dos parâmetros via mínimos quadrados recuperou precisamente os valores originais utilizados na simulação:

- $\hat{\beta} = 0.9000$
- $\hat{\gamma} = 0.1429$

Do ponto de vista analítico, esse resultado é esperado, uma vez que a simulação considerada é estritamente **determinística**. Na ausência de ruído estocástico ou erros de medição, os dados simulados (y) obedecem exatamente às relações lineares impostas pela matriz de regressores (H). Nesse cenário, o método de mínimos quadrados é capaz de recuperar os parâmetros teóricos de forma exata, evidenciando a consistência do procedimento de estimação em condições ideais.

Experimento com Conjunto de Dados Reduzido

Com o objetivo de avaliar a robustez da estimação via mínimos quadrados, realiza-se um experimento utilizando uma **subamostra dos dados simulados**. Para isso, selecionam-se os **índices pares** do conjunto original, isto é, $k = 0, 2, 4, \ldots, 348$, correspondendo a aproximadamente metade das observações disponíveis.

Aplicando o mesmo procedimento descrito anteriormente, obtêm-se os seguintes parâmetros estimados:

- $\hat{\beta}_{\text{reduzido}} = 1.7367$
- $\hat{\gamma}_{\text{reduzido}} = 0.2835$

Nota-se que os valores estimados são aproximadamente o **dobro dos parâmetros originais** ($\beta = 0.9$ e $\gamma = 0.1429$). Esse comportamento pode ser explicado pelo aumento do **intervalo temporal efetivo** entre as observações: ao considerar apenas índices pares, cada passo da subamostra passa a representar aproximadamente dois passos do modelo original.

Sob o ponto de vista analítico, assumindo pequenas variações entre instantes consecutivos, pode-se escrever:

$$S_{k+2} - S_k \approx (S_{k+1} - S_k) + (S_{k+2} - S_{k+1}) \approx 2\beta S_k I_k, \tag{23}$$

$$R_{k+2} - R_k \approx 2\gamma I_k. \tag{24}$$

Ao aplicar o ajuste linear $y = \beta x$ ou $y = \gamma x$ aos dados espaçados de dois em dois, o método interpreta essa **diferença ampliada** como um coeficiente maior, resultando em

$\hat{\beta}_{\text{reduzido}} \approx 2\beta$ e $\hat{\gamma}_{\text{reduzido}} \approx 2\gamma$. Esse comportamento evidencia que, embora o método de mínimos quadrados seja consistente em cenários determinísticos completos, a **densidade e o espaçamento dos dados** exercem influência direta na interpretação quantitativa dos parâmetros estimados.

Um aspecto relevante é que, ao simular o modelo SIR com os parâmetros ajustados $(\hat{\beta}_{\text{reduzido}}/2, \hat{\gamma}_{\text{reduzido}}/2)$ e passo unitário $(i = 0, 1, 2, \dots)$, as trajetórias **preservam a tendência geral da dinâmica populacional**. Observa-se que o crescimento inicial, o pico e o subsequente declínio das curvas são reproduzidos de forma consistente, como ilustrado na Figura 3.

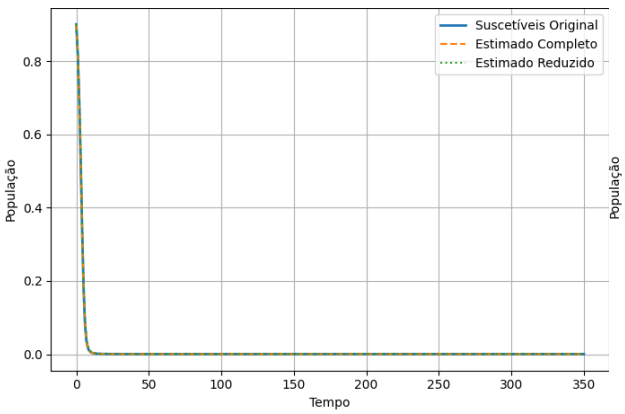

(a) Suscetíveis

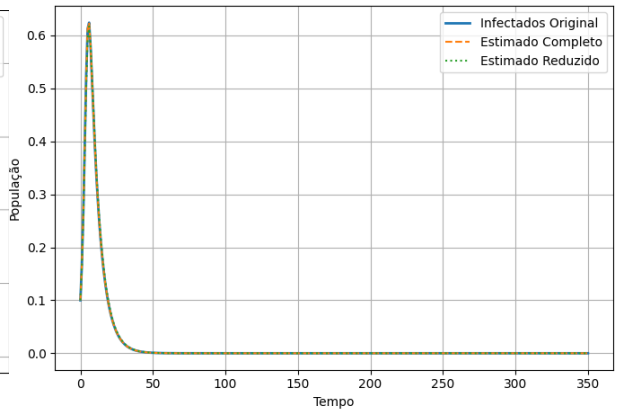

(b) Infectados

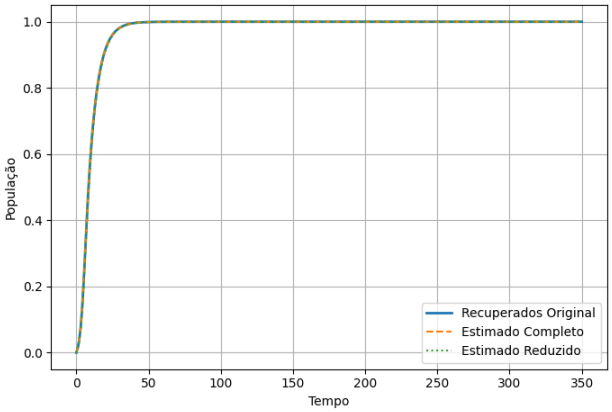

(c) Recuperados

Figura 3: Comparação da reconstrução das populações S_i, I_i e R_i. As linhas tracejadas (laranja e verde) representam a simulação utilizando os parâmetros estimados via dados completos e dados reduzidos, respectivamente, demonstrando que a tendência geral das curvas é preservada em relação à simulação original (azul).

Análise dos Erros

Apesar da boa concordância visual entre as trajetórias, a reconstrução a partir de dados reduzidos apresenta pequenas discrepâncias em relação à simulação original. Como ilustrado na Figura 4, o erro absoluto assume valores máximos entre aproximadamente 0.015 e 0.025 nas regiões de transição mais acentuada, particularmente durante o crescimento da população de infectados e a redução dos suscetíveis. Após esses intervalos, o erro decai gradualmente, tendendo a valores próximos de zero.

A opção pelo uso do erro absoluto, em detrimento do erro relativo, deve-se ao fato de que, no modelo SIR, algumas populações podem assumir valores muito próximos de zero ao longo da simulação. Nesses casos, o erro relativo pode ser artificialmente amplificado, uma vez que pequenas diferenças absolutas passam a ser divididas por valores reduzidos, gerando picos pouco representativos do comportamento real do sistema.

Dessa forma, o erro absoluto fornece uma medida mais estável e interpretável das discrepâncias entre as trajetórias. Os resultados indicam que, mesmo sob uma amostragem reduzida, os desvios permanecem limitados, evidenciando que a dinâmica principal do modelo é preservada.

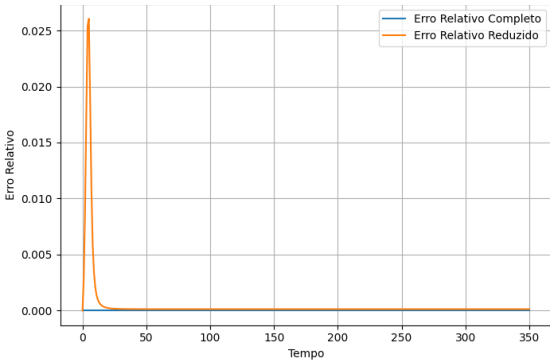

(a) Erro S_i

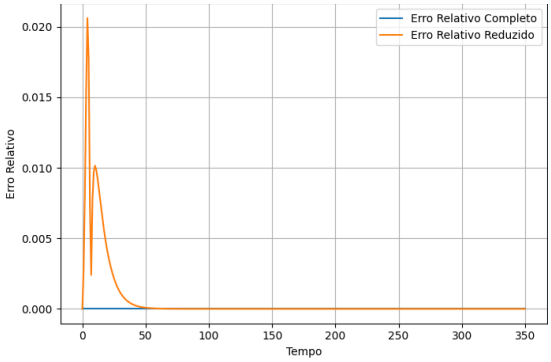

(b) Erro I_i

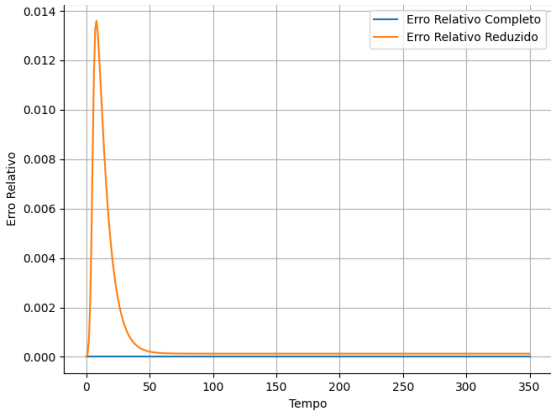

(c) Erro R_i

Figura 4: Evolução do erro absoluto entre a simulação original e a reconstrução com dados reduzidos.

Ajuste de Curvas via Mínimos Quadrados: Renda e Consumo

Nesta etapa, aplica-se a técnica de mínimos quadrados ao ajuste de curvas lineares e quadráticas aos dados de Renda (x) e Consumo (y), evidenciando sua aplicação em contextos econômicos. A análise da relação entre renda e consumo é fundamental para a compreensão do comportamento do consumidor, formulação de políticas econômicas e previsão de demanda. O ajuste de curvas permite estimar funções que representem a tendência média dos dados, identificar possíveis não linearidades e avaliar a dispersão em torno da relação estimada, fornecendo suporte quantitativo para análises mais robustas.

Tabela de Dados: Renda vs. Consumo

A Tabela 1 apresenta os valores observados de renda e consumo utilizados nos ajustes. A partir desses dados, é possível aplicar modelos lineares, quando se assume uma relação aproximadamente proporcional entre as variáveis, bem como modelos quadráticos, capazes de capturar eventuais curvaturas e comportamentos não lineares.

Renda (x)	**Consumo** (y)
139	122
126	114
90	86
144	134
163	146
136	107
61	68
62	117
41	71
120	98

Tabela 1: Dados utilizados para o ajuste de curvas via mínimos quadrados.

Embora ilustrado em um contexto econômico, o procedimento de ajuste apresentado é de caráter geral, sendo amplamente empregado em diversas áreas, como engenharia, ciências sociais e biologia, sempre que há interesse em modelar dados observacionais e identificar tendências.

Formulação do Ajuste via Mínimos Quadrados

Ajuste Linear

Para o ajuste linear, busca-se uma função da forma:

$$y = a_0 + a_1 x \tag{25}$$

em que os coeficientes a_0 e a_1 são determinados pelo método dos mínimos quadrados, que consiste em minimizar a soma dos quadrados dos resíduos:

$$\min_{a_0, a_1} \sum_{i=1}^{n} \left(y_i - (a_0 + a_1 x_i)\right)^2 . \tag{26}$$

Em termos matriciais, o problema pode ser expresso na forma padrão:

$$H^\top H \hat{x} = H^\top y \quad \Rightarrow \quad \hat{x} = (H^\top H)^{-1} H^\top y, \tag{27}$$

em que H é a matriz de regressores, y é o vetor de observações e $\hat{x}$ contém os coeficientes estimados.

Para o modelo linear da Equação 25, a matriz de regressores H_{linear} e o vetor y são dados por:

$$H_{\text{linear}} = \begin{bmatrix} 1 & 139 \\ 1 & 126 \\ 1 & 90 \\ 1 & 144 \\ 1 & 163 \\ 1 & 136 \\ 1 & 61 \\ 1 & 62 \\ 1 & 41 \\ 1 & 120 \end{bmatrix}, \quad y = \begin{bmatrix} 122 \\ 114 \\ 86 \\ 134 \\ 146 \\ 107 \\ 68 \\ 117 \\ 71 \\ 98 \end{bmatrix}. \tag{28}$$

A aplicação da Equação 27 fornece os coeficientes estimados:

$$\hat{x}_{\text{linear}} = \begin{bmatrix} a_0 \\ a_1 \end{bmatrix} = \begin{bmatrix} 52.6930 \\ 0.4954 \end{bmatrix}. \tag{29}$$

Portanto, a curva ajustada é:

$$\hat{y}_{\text{linear}} = 52.6930 + 0.4954\, x. \tag{30}$$

Ajuste Quadrático

Para o ajuste quadrático, considera-se um modelo da forma:

$$y = b_0 + b_1 x + b_2 x^2, \tag{31}$$

em que os coeficientes b_0, b_1 e b_2 são determinados pelo método dos mínimos quadrados, a partir da minimização da função custo:

$$\min_{b_0,b_1,b_2} \sum_{i=1}^{n} \left(y_i - (b_0 + b_1 x_i + b_2 x_i^2)\right)^2. \tag{32}$$

Aplicando a formulação matricial padrão, define-se a matriz de regressores:

$$H_{\text{quadratico}} = \begin{bmatrix} 1 & 139 & 19321 \\ 1 & 126 & 15876 \\ 1 & 90 & 8100 \\ 1 & 144 & 20736 \\ 1 & 163 & 26569 \\ 1 & 136 & 18496 \\ 1 & 61 & 3721 \\ 1 & 62 & 3844 \\ 1 & 41 & 1681 \\ 1 & 120 & 14400 \end{bmatrix}. \tag{33}$$

A aplicação do método dos mínimos quadrados fornece os coeficientes estimados:

$$\hat{x}_{\text{quadratico}} = \begin{bmatrix} b_0 \\ b_1 \\ b_2 \end{bmatrix} = \begin{bmatrix} 91.6270 \\ -0.4297 \\ 0.0046 \end{bmatrix}. \tag{34}$$

Definindo, portanto, a parábola ajustada:

$$\hat{y}_{\text{quadratico}} = 91.6270 - 0.4297\, x + 0.0046\, x^2. \tag{35}$$

Análise Gráfica e Estudo de Erros

A relação entre os modelos linear e quadrático torna-se mais clara ao observar as curvas ajustadas sobre os dados experimentais (Figura 5), bem como por meio da análise quantitativa dos erros residuais. Observa-se uma tendência crescente bem definida entre renda e consumo, embora acompanhada de dispersão significativa, especialmente na faixa intermediária de renda.

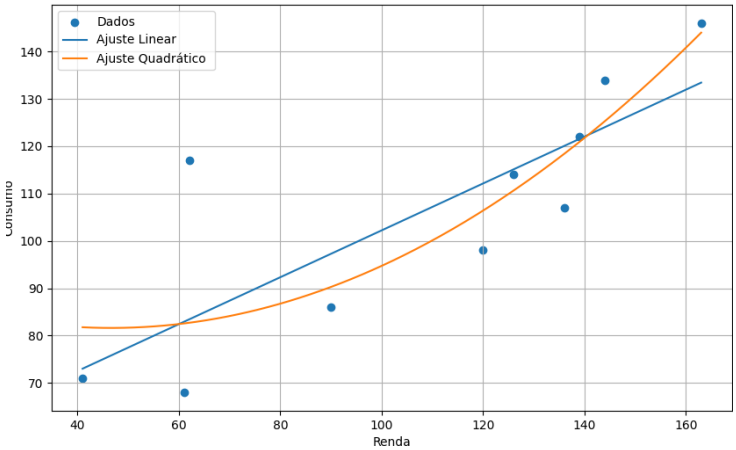

Figura 5: Ajustes linear e quadrático aos dados de Renda vs. Consumo.

O modelo linear consegue capturar essa tendência geral, porém assume uma taxa de crescimento constante, o que limita sua capacidade de ajuste nas extremidades dos dados. Por sua vez, o modelo quadrático introduz uma curvatura suave, permitindo maior flexibilidade na representação da relação entre as variáveis. Esse efeito é mais evidente na região de rendas mais altas, onde o ajuste quadrático acompanha mais de perto os valores observados. Esse melhor desempenho é confirmado pelo menor valor de RMSE.

Ponto	**Renda (x)**	**Erro Relativo (Linear)**	**Erro Relativo (Quadrático)**
1	139	0.0036	0.0088
2	126	0.0098	0.0295
3	90	0.1312	0.0497
4	144	0.0744	0.0649
5	163	0.0860	0.0136
6	136	0.1222	0.1067
7	61	0.2193	0.2141
8	62	0.2871	0.2932
9	41	0.0283	0.1515
10	120	0.1443	0.0859
RMSE	-	**14.5302**	**13.4753**

Tabela 2: Erro relativo ponto a ponto e RMSE para os ajustes linear e quadrático.

A análise dos erros revela discrepâncias mais acentuadas nos pontos 7 e 8, associados a valores semelhantes de renda, mas com níveis de consumo bastante distintos. Esse comportamento sugere a presença de *outliers* ou a influência de variáveis não consideradas no modelo, evidenciando limitações inerentes à modelagem baseada apenas na renda.

Estudo do Ajuste com Restrição de Igualdade

O ajuste por mínimos quadrados com restrição de igualdade tem como objetivo determinar os coeficientes do modelo que minimizam o erro quadrático total, ao mesmo tempo em que satisfazem uma condição previamente estabelecida. O problema restrito incorpora uma informação externa que deve ser respeitada exatamente pela solução. No caso considerado, impõe-se que a curva ajustada passe pelo ponto específico $(x_r, y_r) = (163, 146)$.

Inicialmente, o problema clássico de mínimos quadrados é dado por:

$$\mathbf{H}^T\mathbf{H}\hat{x} = \mathbf{H}^T y, \tag{36}$$

cuja solução fornece os coeficientes que minimizam o erro quadrático sem restrições. Para incorporar a condição adicional, introduz-se a restrição linear:

$$G\hat{x} = u, \tag{37}$$

em que G representa a avaliação da base do modelo no ponto de restrição e u corresponde ao valor desejado (neste caso, $u = 146$). A inclusão dessa restrição leva à construção de um sistema linear aumentado, dado por:

$$\begin{bmatrix} \mathbf{H}^T\mathbf{H} & G^T \\ G & 0 \end{bmatrix} \begin{bmatrix} \hat{x} \\ \lambda \end{bmatrix} = \begin{bmatrix} \mathbf{H}^T y \\ u \end{bmatrix}. \tag{38}$$

Para tornar explícita a implementação desse sistema, apresentam-se as matrizes envolvidas em cada modelo.

Implementação nos Modelos

Ajuste Linear Restrito

Para o modelo linear $y = a_0 + a_1 x$, a matriz de regressores e o vetor de observações são dados por:

$$H = \begin{bmatrix} 1 & 139 \\ 1 & 126 \\ 1 & 90 \\ 1 & 144 \\ 1 & 163 \\ 1 & 136 \\ 1 & 61 \\ 1 & 62 \\ 1 & 41 \\ 1 & 120 \end{bmatrix}, \quad y = \begin{bmatrix} 122 \\ 114 \\ 86 \\ 134 \\ 146 \\ 107 \\ 68 \\ 117 \\ 71 \\ 98 \end{bmatrix}. \tag{39}$$

A imposição de que a reta passe pelo ponto $(163, 146)$ resulta na equação:

$$a_0 + a_1 \cdot 163 = 146, \tag{40}$$

que pode ser escrita na forma matricial como:

$$G = \begin{bmatrix} 1 & 163 \end{bmatrix}, \quad u = \begin{bmatrix} 146 \end{bmatrix}. \tag{41}$$

O sistema aumentado torna-se, portanto:

$$\begin{bmatrix} H^T H & G^T \\ G & 0 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ \lambda \end{bmatrix} = \begin{bmatrix} H^T y \\ 146 \end{bmatrix}. \tag{42}$$

Ajuste Quadrático Restrito

Para o modelo quadrático $y = b_0 + b_1 x + b_2 x^2$, a matriz de regressores é dada por:

$$H = \begin{bmatrix} 1 & 139 & 19321 \\ 1 & 126 & 15876 \\ 1 & 90 & 8100 \\ 1 & 144 & 20736 \\ 1 & 163 & 26569 \\ 1 & 136 & 18496 \\ 1 & 61 & 3721 \\ 1 & 62 & 3844 \\ 1 & 41 & 1681 \\ 1 & 120 & 14400 \end{bmatrix}, \quad y = \begin{bmatrix} 122 \\ 114 \\ 86 \\ 134 \\ 146 \\ 107 \\ 68 \\ 117 \\ 71 \\ 98 \end{bmatrix}. \tag{43}$$

A restrição imposta é:

$$b_0 + b_1 \cdot 163 + b_2 \cdot 163^2 = 146, \tag{44}$$

ou, equivalentemente:

$$G = \begin{bmatrix} 1 & 163 & 163^2 \end{bmatrix}. \tag{45}$$

O sistema aumentado correspondente é:

$$\begin{bmatrix} H^T H & G^T \\ G & 0 \end{bmatrix} \begin{bmatrix} b_0 \\ b_1 \\ b_2 \\ \lambda \end{bmatrix} = \begin{bmatrix} H^T y \\ 146 \end{bmatrix}. \tag{46}$$

Após a aplicação do método de mínimos quadrados com restrição de igualdade, obtêm-se os seguintes modelos ajustados:

$$\hat{y}_{\text{linear}} = 0.6459\,x + 40.7145, \tag{47}$$

$$\hat{y}_{\text{quadrático}} = 0.0051\,x^2 - 0.5176\,x + 94.9366. \tag{48}$$

Observa-se que, em ambos os casos, as funções ajustadas passam exatamente pelo ponto imposto, evidenciando o efeito direto da restrição sobre os coeficientes estimados. Esse tipo de abordagem é particularmente útil quando há pontos de referência que devem ser rigorosamente respeitados, ainda que isso implique uma leve alteração no ajuste global em relação ao caso não restrito.

Análise dos Resultados

A Tabela 3 apresenta os erros relativos ponto a ponto e o RMSE dos modelos ajustados sob a restrição imposta. Observa-se que o Ponto 5 ($x = 163$) possui erro nulo em ambos os casos, confirmando que a condição de igualdade foi corretamente incorporada ao processo de estimação.

Ponto	**Erro Relativo (Linear)**	**Erro Relativo (Quadrático)**
1	0.0697	0.0043
2	0.0711	0.0294
3	0.1494	0.0423
4	0.0020	0.0589
5	**0.0000**	**0.0000**
6	0.2015	0.1105
7	0.1782	0.2107
8	0.3097	0.2954
9	0.0536	0.1589
10	0.2064	0.0840
RMSE	16.2829	13.4973

Tabela 3: Erros relativos ponto a ponto e RMSE para os ajustes linear e quadrático restritos ao ponto $(163, 146)$.

Ao comparar os resultados com os obtidos no ajuste sem restrição, nota-se que o modelo linear sofre impacto significativo, com o RMSE aumentando de 14.53 para 16.28. Esse comportamento indica que a imposição da restrição força a reta a se ajustar para atender ao ponto específico, alterando sua inclinação e comprometendo a qualidade do ajuste em outras regiões, especialmente nos pontos intermediários.

Por outro lado, o modelo quadrático mantém praticamente o mesmo desempenho (13.49 contra 13.4973), evidenciando maior flexibilidade estrutural. A presença do termo x^2 permite ao modelo acomodar a restrição local sem distorcer de forma significativa o comportamento global da curva.

Essa diferença torna-se evidente na Figura 6, na qual se observa que a reta linear sofre uma rotação mais acentuada para satisfazer a restrição, enquanto a curva quadrática ajusta-se de maneira mais suave, preservando a tendência geral dos dados.

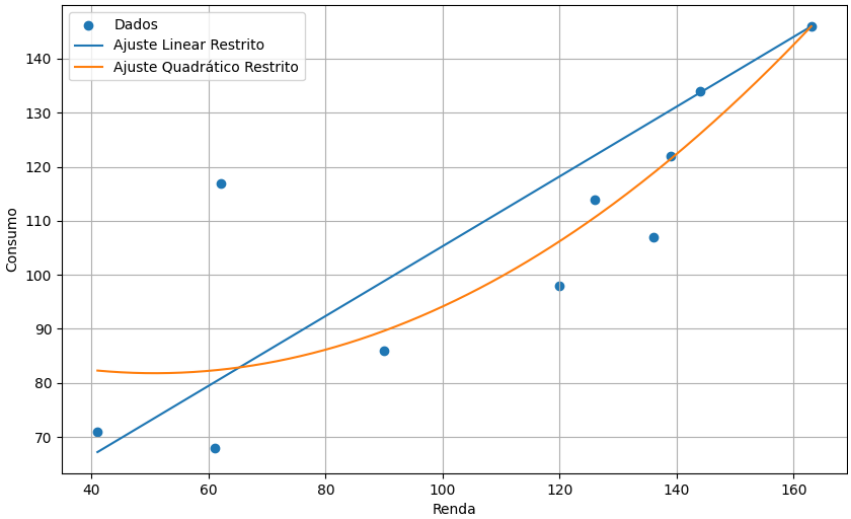

Figura 6: Ajustes linear e quadrático restritos ao ponto $(163, 146)$.

De forma geral, os resultados evidenciam que modelos mais simples são mais sensíveis à imposição de restrições pontuais, enquanto modelos com maior grau de liberdade conseguem absorver essas condições com menor impacto na qualidade global do ajuste.

Conclusão

Ao longo deste trabalho, foram exploradas aplicações de métodos numéricos em dois contextos distintos, porém complementares: a modelagem de sistemas dinâmicos e o ajuste de curvas a dados observacionais.

Na etapa dedicada ao modelo epidemiológico SIR discreto, foi possível descrever a evolução temporal das populações suscetível, infectada e recuperada, evidenciando o papel dos parâmetros β e γ na dinâmica do sistema. A estimação desses parâmetros por meio do método dos mínimos quadrados mostrou-se consistente, sendo capaz de recuperar com elevada precisão os valores utilizados na simulação. Além disso, a análise com dados reduzidos revelou que, mesmo sob menor densidade amostral, a estrutura dinâmica do modelo é preservada, desde que se considere adequadamente a escala temporal envolvida.

Na segunda parte, o estudo concentrou-se no ajuste de modelos lineares e quadráticos para descrever a relação entre renda e consumo. Observou-se que, embora o modelo linear capture a tendência geral, o modelo quadrático apresenta maior capacidade de adaptação a possíveis não linearidades, resultando em melhor desempenho global. A inclusão de uma restrição de igualdade evidenciou, ainda, o impacto de informações externas sobre o processo de estimação, destacando a diferença de comportamento entre modelos mais rígidos e aqueles com maior flexibilidade estrutural.

De forma integrada, os resultados obtidos demonstram que métodos numéricos não apenas permitem ajustar modelos a dados, mas também oferecem ferramentas para interpretar fenômenos complexos, avaliar limitações dos modelos adotados e incorporar condições adicionais de forma sistemática. Assim, reforça-se a importância dessas técnicas na análise quantitativa de problemas reais, tanto em contextos científicos quanto aplicados.