UNIVERSIDADE ESTADUAL DE SANTA CRUZ

Mestrado em Modelagem Computacional

Projeto 2

TEORIA DA ESTIMAÇÃO

Professor: Gildson Queiroz de Jesus

Aluno: João Vitor Nascimento Ramos

Ilhéus – BA

Abril 2026

Introdução

A estimação de estados em sistemas dinâmicos constitui um problema central em áreas como engenharia, economia e modelagem matemática, especialmente em situações nas quais o estado do sistema não pode ser observado diretamente. Na prática, as informações disponíveis são obtidas por meio de medições sujeitas a ruído, o que dificulta a reconstrução precisa do comportamento real do sistema.

Além disso, a própria dinâmica do sistema pode apresentar incertezas, sendo frequentemente modelada por meio de equações que incorporam ruído de processo. Dessa forma, tanto a evolução do estado quanto as observações disponíveis estão sujeitas a perturbações aleatórias, tornando necessária a utilização de técnicas de estimação que sejam capazes de lidar com essas fontes de incerteza.

Neste contexto, o filtro de Kalman se destaca como uma ferramenta eficiente para a estimação de estados em sistemas lineares sujeitos a ruídos gaussianos. Trata-se de um algoritmo recursivo que combina informações provenientes do modelo dinâmico e das medições disponíveis, produzindo uma estimativa ótima no sentido de mínima variância do erro.

O funcionamento do filtro baseia-se em duas etapas principais: predição e correção. Na etapa de predição, o estado do sistema é estimado a partir do modelo dinâmico, enquanto na etapa de correção essa estimativa é ajustada com base nas medições observadas. Esse mecanismo permite equilibrar a confiança entre o modelo e as observações, levando em consideração as incertezas associadas a cada uma dessas fontes de informação.

Neste trabalho, o filtro de Kalman é aplicado a modelos dinâmicos simulados, com o objetivo de analisar seu desempenho na estimação do estado em presença de ruído de processo e ruído de observação. São consideradas diferentes formulações do filtro, incluindo a estimativa filtrada, a estimativa preditiva e a abordagem preditiva-corretiva, permitindo avaliar o impacto de cada uma dessas estratégias na qualidade das estimativas obtidas.

Os resultados são analisados por meio de comparações visuais e métricas quantitativas, com destaque para o erro quadrático médio normalizado (NRMSE), possibilitando uma avaliação consistente do desempenho das técnicas de estimação consideradas.

Modelo Estocástico para Preços

Como primeira etapa deste estudo, considera-se um modelo estocástico para a evolução de preços, descrito por uma equação de estado com ruído de processo e uma equação de observação com ruído de medição. Esse tipo de modelagem permite representar, de forma mais realista, a dinâmica de sistemas sujeitos a incertezas e variações aleatórias ao longo do tempo.

A equação de estado que descreve a evolução do preço é dada por:

$$p(k+1) = p(k) + \left(\mu - \frac{1}{2}\sigma^2\right)\Delta t + \sigma\sqrt{\Delta t}\, dz \tag{1}$$

em que $p(k)$ representa o preço no instante discreto k, μ é a taxa média de crescimento, σ corresponde à volatilidade do sistema, Δt é o passo de tempo e dz é uma variável aleatória gaussiana padrão, responsável por introduzir o ruído de processo.

Neste modelo, o termo determinístico define a tendência média de crescimento do preço ao longo do tempo, enquanto o termo estocástico introduz flutuações aleatórias em torno dessa tendência. Dessa forma, o comportamento do sistema não é completamente previsível, refletindo melhor situações reais, como aquelas observadas em mercados financeiros.

Além disso, assume-se que as medições do preço não são perfeitas, sendo afetadas por ruído de observação. Assim, o valor observado não coincide exatamente com o estado real do sistema, o que justifica a necessidade de técnicas de estimação capazes de recuperar o estado real do sistema a partir de medições ruidosas.

Nesse contexto, o modelo adotado fornece uma base adequada para a aplicação do filtro de Kalman, permitindo analisar como diferentes fontes de incerteza afetam a estimação do estado e como essas perturbações podem ser atenuadas por meio de métodos apropriados.

Simulação do Modelo

Para analisar a dinâmica do sistema, foram geradas duas trajetórias distintas:

- Uma trajetória **determinística**, obtida a partir da equação de estado sem o termo de ruído;
- Uma trajetória **estocástica**, na qual é incorporado o ruído de processo.

Para a realização das simulações, foram adotados os seguintes parâmetros:

- Taxa de crescimento: $\mu = 0.05$
- Volatilidade: $\sigma = 0.2$
- Passo de tempo: $\Delta t = 1$
- Número de passos: $N = 1000$
- Condição inicial: $p(0) = 10$

A Figura 1 apresenta a comparação entre a trajetória determinística e a trajetória estocástica do sistema.

Para essa simulação específica, foi fixada a semente do gerador de números pseudo-aleatórios como `seed` $= 0$. A escolha de uma semente fixa garante a reprodutibilidade dos resultados e permite obter a mesma sequência de valores aleatórios, o que resulta na mesma trajetória estocástica em diferentes execuções do experimento.

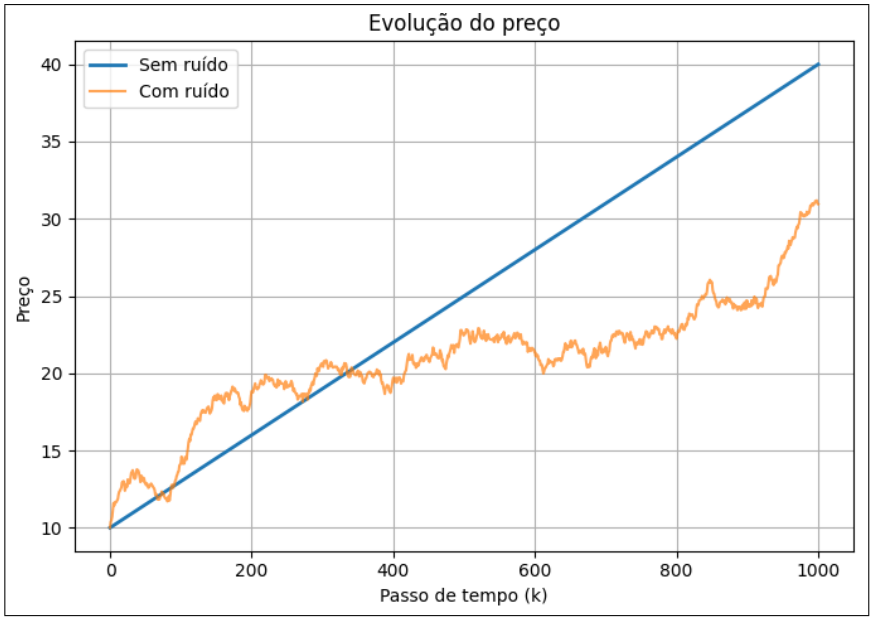

Figura 1: Comparação entre a trajetória determinística (sem ruído) e a trajetória estocástica (com ruído de processo).

Análise do Erro de Processo

Para complementar a análise da dinâmica do sistema, considera-se o erro de trajetória, definido como a diferença entre a trajetória estocástica e a trajetória determinística:

$$e_k = p_k^{\text{ruído}} - p_k^{\text{determinístico}} \tag{2}$$

A Figura 2 apresenta a evolução desse erro ao longo do tempo.

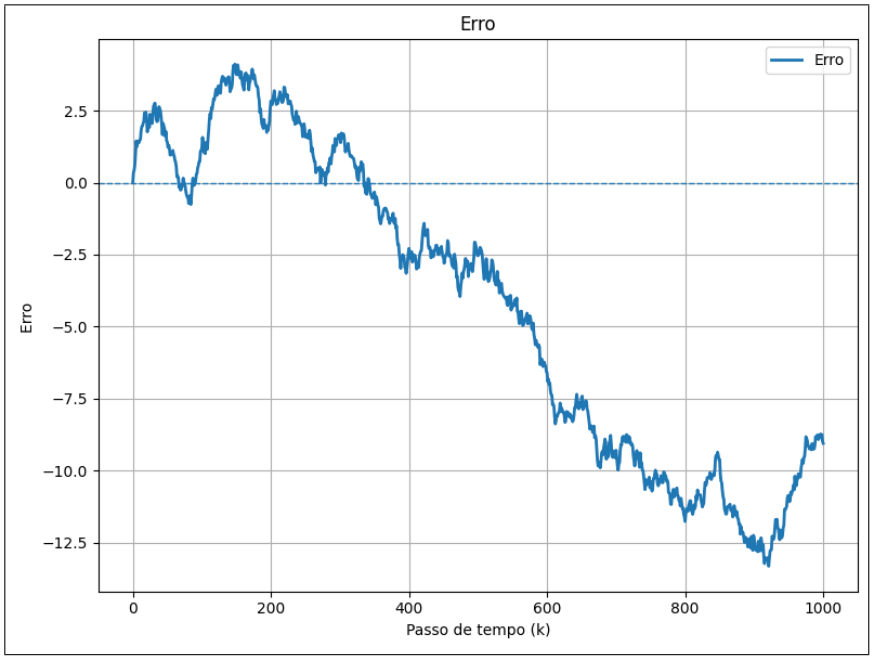

Figura 2: Evolução do erro de processo ao longo do tempo.

A análise do erro de processo foi realizada em duas etapas.

Inicialmente, considera-se o erro com sinal, definido como a diferença entre a trajetória estocástica e a determinística. Esse erro permite observar as oscilações em torno da trajetória de referência. Nos instantes iniciais, o erro permanece próximo de zero, mas cresce ao longo do tempo, evidenciando o efeito acumulativo do ruído de processo.

Para quantificar esse desvio, utiliza-se o erro quadrático médio normalizado (NRMSE). Para a realização considerada (`seed` $= 0$), obteve-se:

$$\text{NRMSE} = 0.2729 \tag{3}$$

Esse valor confirma o aumento progressivo do desvio ao longo do tempo. Dessa forma, a análise conjunta do erro com sinal e do NRMSE permite avaliar o impacto do ruído de processo na dinâmica do sistema.

Influência da Semente do Gerador Pseudoaleatório

Como o modelo é estocástico, a trajetória gerada depende da realização do ruído de processo, determinada pela semente do gerador de números pseudoaleatórios. Para evidenciar essa variabilidade, considera-se uma segunda simulação com `seed` = 42, mantendo-se os mesmos parâmetros do sistema. A Figura 3 apresenta a trajetória obtida e o erro de processo correspondente.

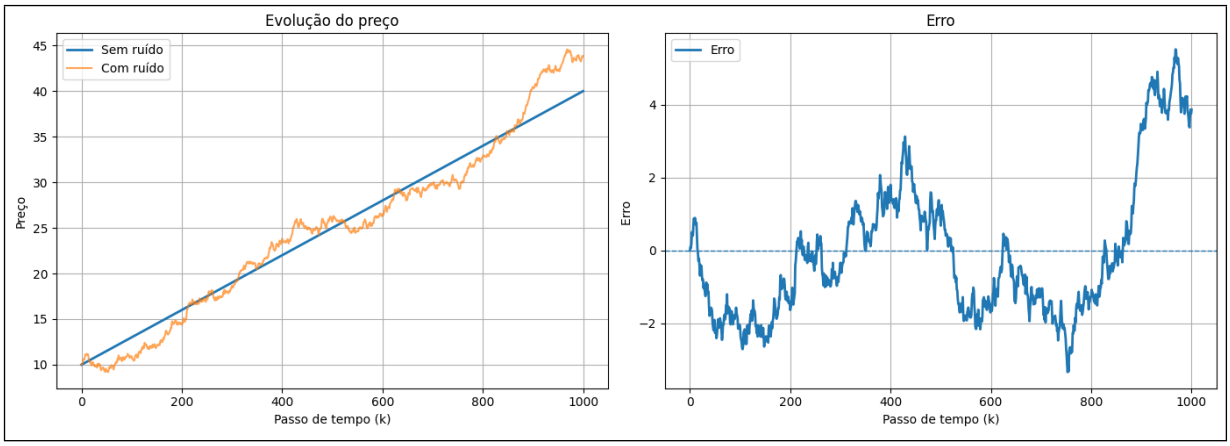

Figura 3: Trajetória estocástica e erro de processo para `seed` = 42.

Observa-se que, nessa realização, a trajetória permanece mais próxima da determinística, com flutuações mais suaves.

Para quantificar esse comportamento, calcula-se o NRMSE, obtendo-se:

$$\text{NRMSE} = 0.0765 \tag{4}$$

Comparando com a realização anterior (`seed` = 0, com NRMSE = 0.2729), verifica-se uma diferença significativa entre os resultados. Isso mostra que diferentes sementes geram trajetórias distintas, mesmo com os mesmos parâmetros, reforçando a necessidade de múltiplas simulações para uma análise mais robusta.

Análise Estatística com Múltiplas Simulações

Para obter uma avaliação mais robusta do impacto do ruído de processo, foram realizadas múltiplas simulações com diferentes sementes aleatórias. Considerando 1000 realizações, obteve-se:

$$\overline{\text{NRMSE}} = 0.1623 \tag{5}$$

Esse valor permaneceu praticamente inalterado ao considerar 10000 simulações, indicando a convergência da média amostral. Assim, embora trajetórias individuais apresentem comportamentos distintos, o efeito médio do ruído de processo tende a se estabilizar.

Influência da Intensidade do Ruído de Processo

Para analisar o impacto da intensidade do ruído de processo, foi realizada uma variação do parâmetro de volatilidade, mantendo-se os demais parâmetros fixos. A Figura 4 apresenta a evolução do NRMSE em função dessa intensidade, considerando a realização com `seed` = 42.

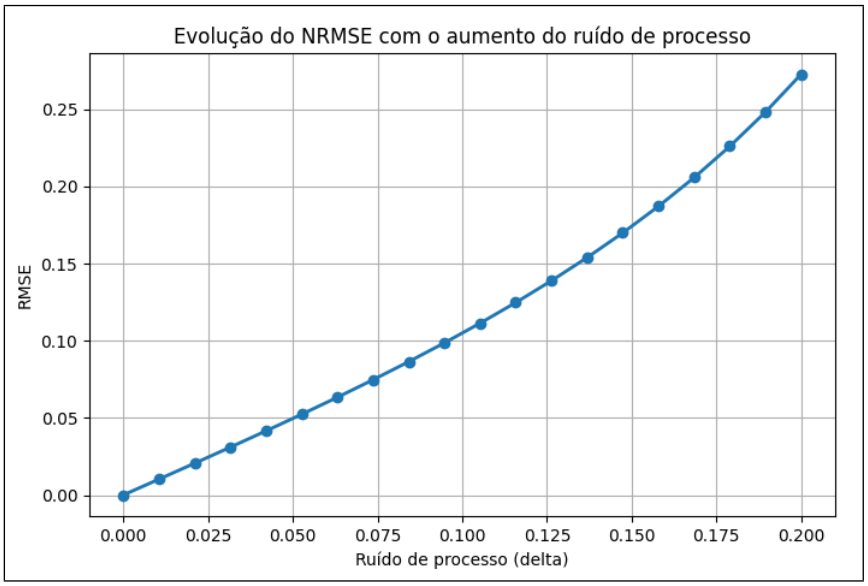

Figura 4: Evolução do NRMSE em função da intensidade do ruído de processo.

Observa-se que o NRMSE cresce de forma consistente à medida que a intensidade do ruído aumenta, indicando que perturbações mais intensas na dinâmica do sistema resultam em desvios maiores em relação à trajetória determinística. Esse comportamento é esperado, uma vez que o ruído de processo atua diretamente na evolução do estado, acumulando seus efeitos ao longo do tempo.

Embora o gráfico apresentado corresponda a uma única realização, verificou-se que a tendência observada se mantém para diferentes sementes. Isso indica que a relação entre a intensidade do ruído e o erro não depende de uma realização específica, mas está associada ao próprio modelo.

Dessa forma, o parâmetro de volatilidade desempenha um papel central na dinâmica do sistema, controlando o nível de incerteza e influenciando diretamente a dispersão das trajetórias geradas.

Modelo de Observação e Análise das Medições

Até o momento, considerou-se apenas a dinâmica do sistema, na qual o estado evolui ao longo do tempo sob a influência do ruído de processo. No entanto, em aplicações reais, esse estado não é diretamente acessível, sendo observado por meio de medições sujeitas a incertezas.

Para representar esse cenário, introduz-se a equação de observação:

$$y_k = p_k + \eta r + q\,\varepsilon_k \tag{6}$$

em que y_k representa a medição no instante k, enquanto p_k corresponde ao estado real do sistema. O termo $q\,\varepsilon_k$, com $\varepsilon_k \sim \mathcal{N}(0,1)$, modela o ruído de medição, sendo responsável pelas flutuações aleatórias nas observações. O parâmetro q controla a intensidade desse ruído e o nível de incerteza associado às medições.

Além disso, o termo ηr representa uma tendência sistemática constante, introduzindo um deslocamento nas medições. Dessa forma, as medições podem ser interpretadas como versões ruidosas do estado do sistema.

Comparação entre Estado Real e Medições

Inicialmente, considera-se a realização com `seed` $= 0$. A Figura 5 apresenta a comparação entre o estado real (com ruído de processo) e as medições obtidas.

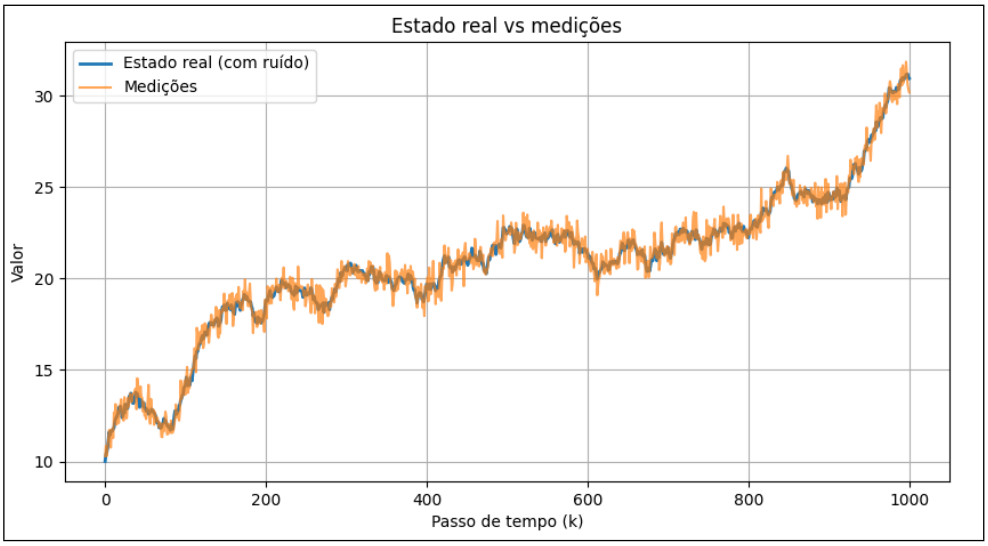

Figura 5: Comparação entre o estado real (com ruído de processo) e as medições, para `seed` $= 0$.

Observa-se que as medições acompanham de forma bastante próxima a trajetória do estado real, apresentando apenas pequenas flutuações adicionais. Essas variações são decorrentes exclusivamente do ruído de observação, que atua de forma independente a cada instante.

Análise do Erro de Medição

Define-se o erro de medição como:

$$e_k^{\text{med}} = y_k - p_k \tag{7}$$

A Figura 6 apresenta a evolução desse erro ao longo do tempo.

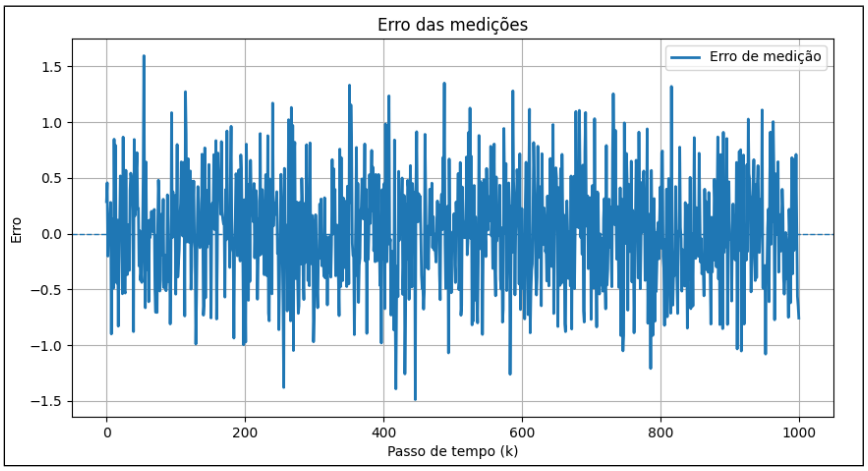

Figura 6: Erro de medição ao longo do tempo, para `seed` $= 0$.

Observa-se que o erro oscila em torno de zero, com amplitude aproximadamente constante, indicando que o ruído de medição não se acumula ao longo do tempo, atuando apenas como uma perturbação local nas observações. Para quantificar esse efeito, calcula-se o NRMSE entre o estado real e as medições. Para duas realizações distintas, obteve-se:

$$\text{NRMSE}_{\text{med}}(\texttt{seed} = 0) = 0.0233 \quad \text{e} \quad \text{NRMSE}_{\text{med}}(\texttt{seed} = 42) = 0.0200 \tag{8}$$

Os valores são próximos, indicando que, embora as realizações individuais sejam diferentes, o nível de erro introduzido pelo ruído de medição permanece relativamente estável. Ao considerar 1000 simulações, obteve-se:

$$\overline{\text{NRMSE}}_{\text{med}} = 0.1586 \tag{9}$$

Esse resultado fornece uma medida global do impacto do ruído de observação. Observa-se que, apesar das oscilações locais serem pequenas em realizações individuais, a média ao longo de múltiplas simulações captura de forma mais representativa a variabilidade introduzida pelo ruído. Diferentemente do ruído de processo, o ruído de medição não afeta a evolução do estado, atuando apenas nas observações.

Essa característica é fundamental, pois indica que as medições, embora ruidosas, contêm informação confiável sobre o estado em cada instante. Dessa forma, torna-se possível combinar essas observações com o modelo dinâmico para obter estimativas mais precisas, motivando a aplicação do filtro de Kalman.

Filtro de Kalman

Diante da presença de ruído tanto na dinâmica do sistema quanto nas medições, torna-se necessário estimar o estado real a partir das informações disponíveis. Para isso, utiliza-se o filtro de Kalman, que fornece uma estimativa ótima do estado em sistemas lineares com ruído gaussiano.

O modelo considerado pode ser descrito pelas equações:

$$x_{k+1} = F_k x_k + w_k \tag{10}$$

$$y_k = H_k x_k + v_k \tag{11}$$

em que x_k representa o vetor de estado, y_k a medição, w_k o ruído de processo e v_k o ruído de medição.

A primeira equação descreve a evolução do estado ao longo do tempo, incorporando as incertezas associadas à dinâmica do sistema. Já a segunda equação relaciona o estado às medições disponíveis, as quais são afetadas por ruído de observação.

No caso em estudo, o estado é definido como:

$$x_k = \begin{bmatrix} p_k \\ 1 \end{bmatrix} \tag{12}$$

Essa escolha permite representar o modelo de forma linear, incorporando o termo constante associado à tendência do sistema.

As matrizes do sistema são dadas por:

$$F_k = \begin{bmatrix} 1 & b \\ 0 & 1 \end{bmatrix}, \quad H_k = \begin{bmatrix} 1 & \eta r \end{bmatrix} \tag{13}$$

com $b = (\mu - \frac{1}{2}\sigma^2)\Delta t$.

A matriz F_k descreve a dinâmica do sistema, determinando como o estado evolui de um instante para o outro. Já a matriz H_k estabelece a relação entre o estado e a medição, indicando como o valor observado é obtido a partir do estado real.

A partir dessa formulação, o filtro de Kalman combina as informações do modelo dinâmico e das medições disponíveis, levando em conta as incertezas associadas a cada uma dessas fontes, com o objetivo de produzir uma estimativa mais precisa do estado do sistema ao longo do tempo.

Estimativa Ótima Filtrada

A estimativa filtrada do filtro de Kalman pode ser obtida a partir do algoritmo recursivo apresentado a seguir.

Passo 0 (Inicialização):

$$P_{0|0} = \left(P_0^{-1} + H_0^T R_0^{-1} H_0\right)^{-1} \tag{14}$$

$$\hat{x}_{0|0} = P_{0|0} H_0^T R_0^{-1} y_0 \tag{15}$$

Passo 1 (Atualização Recursiva):

$$P_{k+1|k+1} = \left[\left(F_k P_{k|k} F_k^T + Q_k\right)^{-1} + H_{k+1}^T R_{k+1}^{-1} H_{k+1}\right]^{-1} \tag{16}$$

$$\hat{x}_{k+1|k+1} = F_k \hat{x}_{k|k} + P_{k+1|k+1} H_{k+1}^T R_{k+1}^{-1} \left(y_{k+1} - H_{k+1} F_k \hat{x}_{k|k}\right) \tag{17}$$

Nesse algoritmo, a estimativa filtrada $\hat{x}_{k|k}$ é atualizada recursivamente a partir da dinâmica do sistema e das medições disponíveis. A matriz $P_{k|k}$ representa a covariância do erro de estimação, enquanto os termos associados a R^{-1} ajustam o peso atribuído às medições. Dessa forma, o filtro combina as duas fontes de informação para produzir uma estimativa mais próxima do estado real.

Análise dos Resultados da Estimativa Filtrada

A Figura 7 apresenta a comparação entre a trajetória determinística, o estado real do sistema e a estimativa filtrada, considerando `seed` = 42, utilizada apenas para fins ilustrativos.

A Figura 8 apresenta a evolução do erro entre a estimativa filtrada e o estado real do sistema para a mesma realização.

Observa-se que a estimativa filtrada acompanha de forma bastante próxima o estado real, capturando tanto a tendência global quanto as variações locais do sistema. Nota-se, entretanto, um desvio mais acentuado nos instantes iniciais, decorrente da escolha da condição inicial do filtro, que não coincide exatamente com o estado real do sistema. Esse comportamento também aparece no gráfico do erro, no qual se observa uma discrepância inicial maior, seguida de rápida redução à medida que novas observações são incorporadas.

Após esse período inicial, o erro passa a oscilar em torno de zero, indicando que a estimativa permanece bem alinhada ao estado real ao longo do tempo. Assim, apesar do impacto inicial causado pela condição inicial, o filtro corrige progressivamente essa discrepância e produz uma estimativa consistente da trajetória observada.

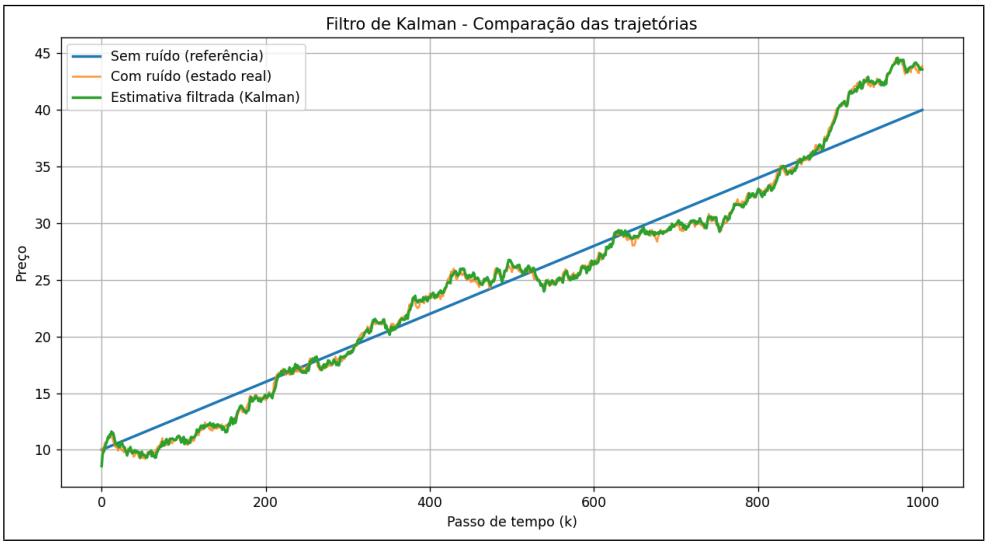

Figura 7: Comparação entre a trajetória determinística, o estado real com ruído de processo e a estimativa filtrada obtida pelo filtro de Kalman.

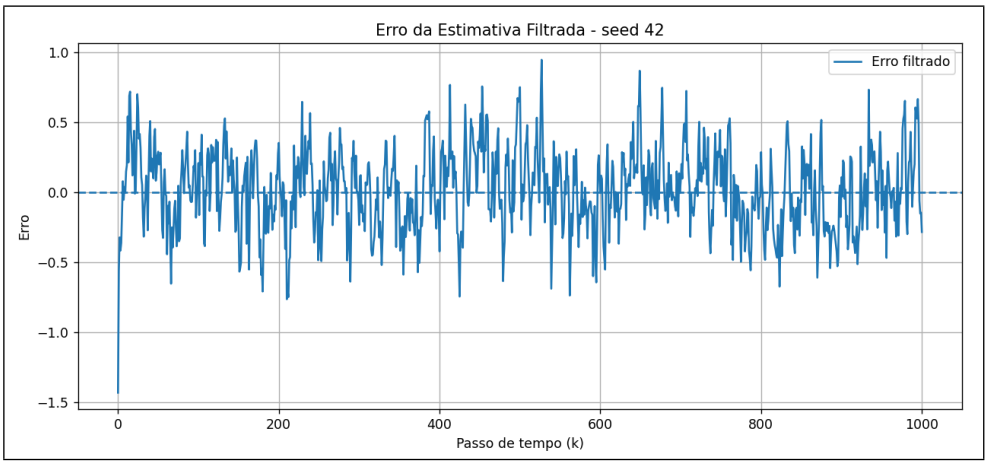

Figura 8: Evolução do erro entre a estimativa filtrada e o estado real do sistema para `seed` = 42.

Do ponto de vista quantitativo, o erro foi avaliado por meio do NRMSE médio ao longo de 1000 realizações, obtendo-se:

$$\overline{\mathrm{NRMSE}}_{\mathrm{Kalman}} = 0.012048 \tag{18}$$

Comparando com o erro médio das medições ($\overline{\mathrm{NRMSE}}_{\mathrm{med}} \approx 0.16$), observa-se uma redução de aproximadamente 92% no erro. Esse resultado é consistente com o objetivo do filtro, que consiste em estimar o estado real do sistema a partir de medições ruidosas. Embora a condição inicial provoque um erro mais elevado nos primeiros instantes, sua influência é reduzida rapidamente pelo processo recursivo de correção.

Dessa forma, os resultados confirmam a eficácia do filtro de Kalman na reconstrução do estado em sistemas dinâmicos sujeitos a incertezas.

Estimativa Preditiva

A estimativa preditiva pode ser obtida a partir de um algoritmo recursivo, conforme apresentado a seguir.

Passo 0 (Inicialização):

$$P_{0|-1} = P_0 \tag{19}$$

$$\hat{x}_{0|-1} = \hat{x}_0 \tag{20}$$

Passo 1 (Atualização Recursiva):

$$P_{k+1|k} = F_k P_{k|k-1} F_k^T + Q_k - F_k P_{k|k-1} H_k^T \left(H_k P_{k|k-1} H_k^T + R_k\right)^{-1} H_k P_{k|k-1} F_k^T \tag{21}$$

$$\hat{x}_{k+1|k} = F_k \hat{x}_{k|k-1} + F_k P_{k|k-1} H_k^T \left(H_k P_{k|k-1} H_k^T + R_k\right)^{-1} \left(y_k - H_k \hat{x}_{k|k-1}\right) \tag{22}$$

Nesse algoritmo, a estimativa preditiva $\hat{x}_{k+1|k}$ corresponde à previsão do estado no instante seguinte, incorporando implicitamente a informação disponível até o instante k. Observa-se que essa formulação apresenta uma forma compacta do processo preditivo, na qual os efeitos da correção anterior são incorporados diretamente na atualização da previsão. Assim, a estimativa preditiva permite descrever a evolução esperada do sistema com base nas informações acumuladas até o instante anterior.

Resultados da Estimativa Preditiva

Para avaliar o desempenho da estimativa preditiva, foi realizada a comparação entre a trajetória determinística, o estado real do sistema e a estimativa preditiva obtida pelo filtro de Kalman. Para fins de ilustração, foi novamente considerada a realização com `seed` = 42. A Figura 9 apresenta essa comparação.

A Figura 10 apresenta a evolução do erro da estimativa preditiva em relação ao estado real do sistema para a mesma realização.

Observa-se que a estimativa preditiva acompanha adequadamente a tendência do sistema, mantendo boa aderência ao estado real ao longo do tempo. Entretanto, diferentemente da estimativa filtrada, pequenas discrepâncias são mais persistentes, uma vez que essa formulação não incorpora diretamente a medição no instante atual.

O gráfico do erro evidencia esse comportamento: após um desvio inicial mais acentuado — decorrente da escolha do chute inicial $\hat{x}_0 = 8$, inferior ao estado real — o erro é rapidamente reduzido e passa a oscilar em torno de zero. Essas oscilações refletem a influência do ruído de processo e a ausência de correção imediata baseada nas medições, resultando em uma estimativa ligeiramente menos precisa ao longo do tempo.

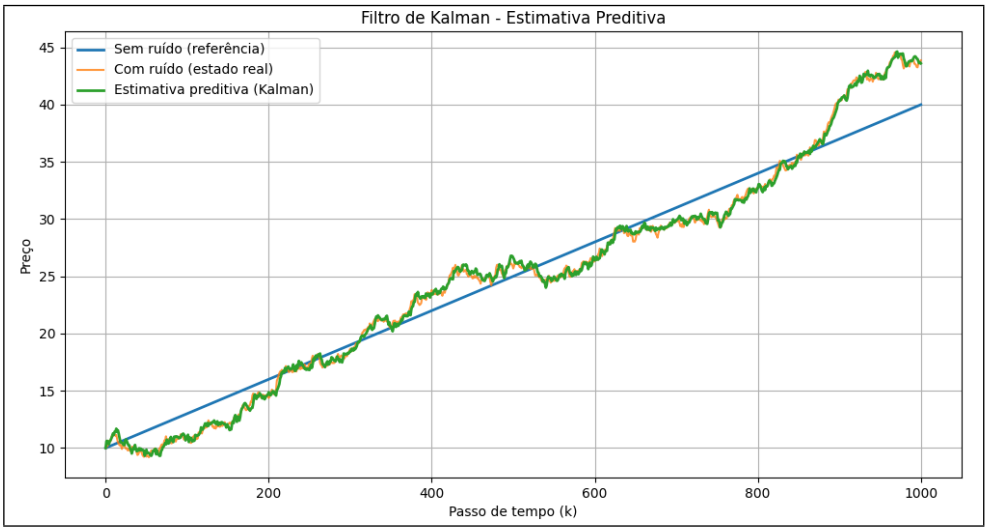

Figura 9: Comparação entre a trajetória determinística, o estado real com ruído de processo e a estimativa preditiva obtida pelo filtro de Kalman.

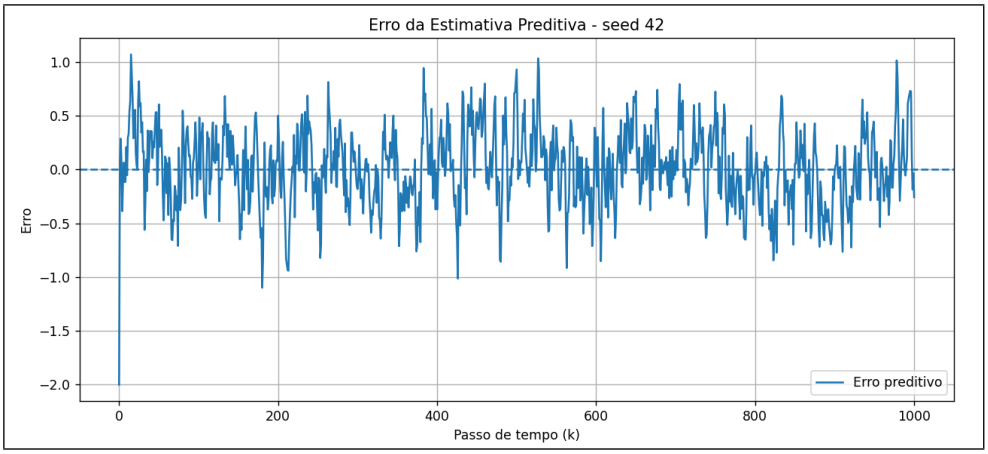

Figura 10: Evolução do erro da estimativa preditiva em relação ao estado real para `seed` = 42.

Do ponto de vista quantitativo, ao considerar 1000 realizações independentes, obteve-se:

$$\overline{\mathrm{NRMSE}}_{\mathrm{pred}} = 0.014472 \tag{23}$$

Esse valor indica que, embora a estimativa preditiva seja capaz de capturar de forma consistente a dinâmica do sistema, seu desempenho é inferior ao de abordagens que incorporam explicitamente a etapa de correção. Ainda assim, o resultado evidencia que a informação acumulada até o instante anterior é suficiente para produzir uma aproximação razoável do estado real, mesmo na ausência das medições mais recentes.

Estimativa Preditiva-Corretiva

A estimativa preditiva-corretiva corresponde à formulação completa do filtro de Kalman, na qual as etapas de predição e correção são realizadas de forma recursiva a cada instante de tempo.

Passo 0 (Inicialização):

$$P_{0|0} = P_0 \tag{24}$$

$$\hat{x}_{0|0} = \hat{x}_0 \tag{25}$$

Passo 1 (Predição):

$$\hat{x}_{k|k-1} = F_k \hat{x}_{k-1|k-1} \tag{26}$$

$$P_{k|k-1} = F_k P_{k-1|k-1} F_k^T + Q_k \tag{27}$$

Passo 2 (Correção):

$$K_k = P_{k|k-1} H_k^T \left(H_k P_{k|k-1} H_k^T + R_k \right)^{-1} \tag{28}$$

$$\hat{x}_{k|k} = \hat{x}_{k|k-1} + K_k \left(y_k - H_k \hat{x}_{k|k-1} \right) \tag{29}$$

$$P_{k|k} = P_{k|k-1} - K_k H_k P_{k|k-1} \tag{30}$$

Nesse algoritmo, a predição fornece uma estimativa inicial baseada no modelo dinâmico, enquanto a correção ajusta essa estimativa com base na medição disponível. O ganho de Kalman K_k define o equilíbrio entre essas duas fontes de informação, ponderando a confiança no modelo e nas observações.

Resultados da Estimativa Preditiva-Corretiva

Para avaliar o comportamento do algoritmo, foi realizada a comparação entre o estado real do sistema e a estimativa obtida pela formulação preditivo-corretiva do filtro de Kalman. Para fins de ilustração, considera-se `seed` $= 42$. A Figura 11 apresenta essa comparação.

A Figura 12 apresenta a evolução do erro da estimativa em relação ao estado real para a mesma realização.

Observa-se que a estimativa preditivo-corretiva acompanha de forma bastante próxima o estado real ao longo de toda a trajetória, capturando tanto a tendência global quanto as variações locais do sistema. Diferentemente da estimativa preditiva, os desvios são menores e menos persistentes, evidenciando o impacto da etapa de correção.

O gráfico do erro reforça essa análise: após um desvio inicial — decorrente da diferença entre o chute inicial e o estado real — o erro é rapidamente reduzido e passa a oscilar em torno de zero. Essas oscilações possuem menor amplitude quando comparadas à estimativa preditiva, indicando uma estimativa mais precisa e estável ao longo do tempo.

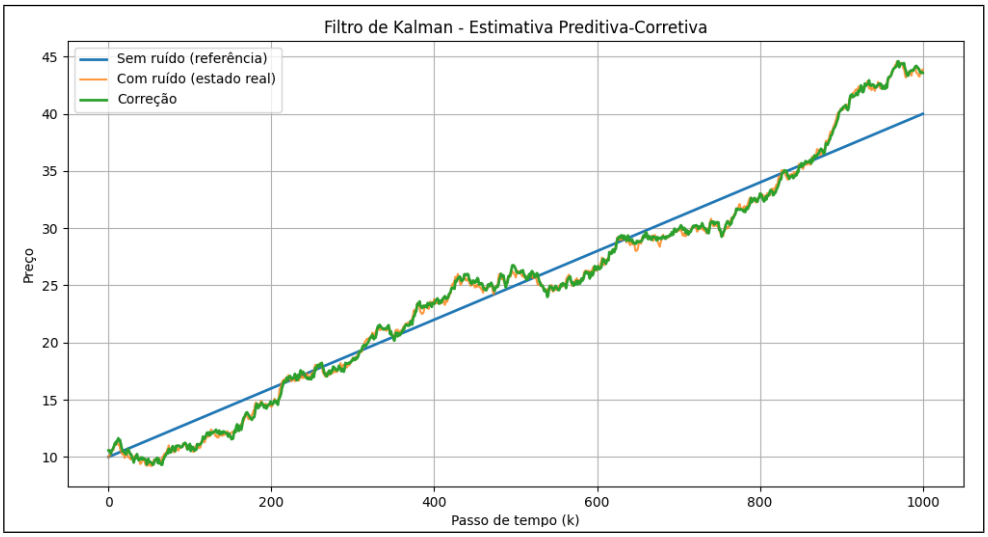

Figura 11: Comparação entre o estado real e a estimativa preditivo-corretiva do filtro de Kalman.

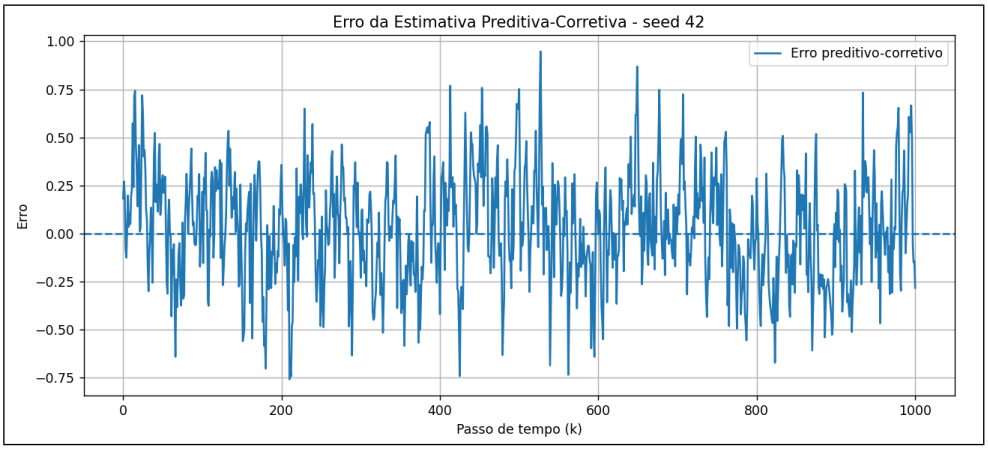

Figura 12: Evolução do erro da estimativa preditivo-corretiva para `seed` = 42.

Do ponto de vista quantitativo, ao considerar 1000 realizações independentes, obteve-se:

$$\overline{\text{NRMSE}}_{\text{pred-cor}} = 0.011667 \tag{31}$$

Comparando com a estimativa preditiva ($\overline{\text{NRMSE}}_{\text{pred}} = 0.014472$), observa-se uma redução no erro de aproximadamente:

$$\frac{0.014472 - 0.011667}{0.014472} \approx 19.4\%$$

evidenciando o papel da etapa de correção na melhoria da estimativa.

Comparando agora com a estimativa filtrada ($\overline{\text{NRMSE}}_{\text{filtrada}} = 0.012048$), a formulação preditivo-corretiva apresentou uma redução de aproximadamente:

$$\frac{0.012048 - 0.011667}{0.012048} \approx 3.2\%$$

Essa diferença é pequena, pois ambas as abordagens estão associadas à estimativa corrigida do filtro, isto é, $\hat{x}_{k|k}$. No entanto, a formulação preditivo-corretiva apresentou desempenho ligeiramente melhor nesse experimento, principalmente devido à forma como a condição inicial foi tratada. Enquanto a estimativa filtrada é mais sensível à inicialização adotada, a abordagem preditivo-corretiva explicita separadamente as etapas de predição e correção, permitindo que o erro inicial seja ajustado de maneira mais direta ao longo das iterações.

Dessa forma, os resultados evidenciam que a incorporação explícita das etapas de predição e correção permite obter estimativas mais precisas e robustas, destacando a importância da atualização recursiva com base nas medições disponíveis.

Modelo Populacional

Considere o modelo de crescimento populacional de Malthus-Verhulst na forma discreta, dado por:

$$P_{k+1} = P_k + (\alpha - \beta)P_k, \quad k = 1, \ldots, N \tag{32}$$

em que P_k representa o número total de indivíduos da população no instante k, α é a taxa de natalidade e β é a taxa de mortalidade.

Esse modelo descreve a evolução da população ao longo do tempo, assumindo crescimento proporcional ao número de indivíduos presentes no sistema.

Modelagem em Espaço de Estados

Para a aplicação do filtro de Kalman, o modelo deve ser representado na forma de espaço de estados. Reescrevendo a equação dinâmica, obtém-se:

$$P_{k+1} = (1 + \alpha - \beta)P_k \tag{33}$$

Definindo o estado como:

$$x_k = P_k \tag{34}$$

o modelo pode ser escrito como:

$$x_{k+1} = Fx_k \tag{35}$$

em que:

$$F = 1 + \alpha - \beta \tag{36}$$

Para tornar o modelo mais realista, introduz-se um termo de ruído de processo:

$$x_{k+1} = Fx_k + w_k \tag{37}$$

em que $w_k \sim \mathcal{N}(0, Q)$ representa o ruído associado à dinâmica do sistema.

Além disso, considera-se que as medições do estado também são afetadas por ruído, sendo descritas por:

$$y_k = x_k + v_k \tag{38}$$

em que $v_k \sim \mathcal{N}(0, R)$ representa o ruído de medição.

Formulação do Problema de Estimação

O objetivo consiste em estimar o estado x_k, que representa o tamanho real da população, a partir de medições ruidosas y_k, utilizando o filtro de Kalman.

O modelo completo é dado por:

$$x_{k+1} = Fx_k + w_k \tag{39}$$

$$y_k = Hx_k + v_k \tag{40}$$

com:

$$H = 1 \tag{41}$$

Dessa forma, busca-se combinar as informações do modelo dinâmico e das medições para obter estimativas mais precisas do estado ao longo do tempo.

Configuração da Simulação

Para a análise do modelo populacional, foram considerados os seguintes parâmetros:

- Taxa de natalidade: $\alpha = 0.03$
- Taxa de mortalidade: $\beta = 0.02$
- Ruído de processo: $\sigma_w = 0.5$
- Ruído de observação: $\sigma_v = 2.0$

Com esses valores, a dinâmica do sistema é caracterizada por um crescimento moderado da população, dado por $F = 1 + \alpha - \beta = 1.01$, indicando um aumento gradual ao longo do tempo.

O ruído de processo foi introduzido para representar incertezas inerentes à dinâmica populacional, enquanto o ruído de observação modela imprecisões nas medições da população.

Para fins de ilustração, a Figura 13 apresenta uma realização do sistema considerando `seed` $= 42$.

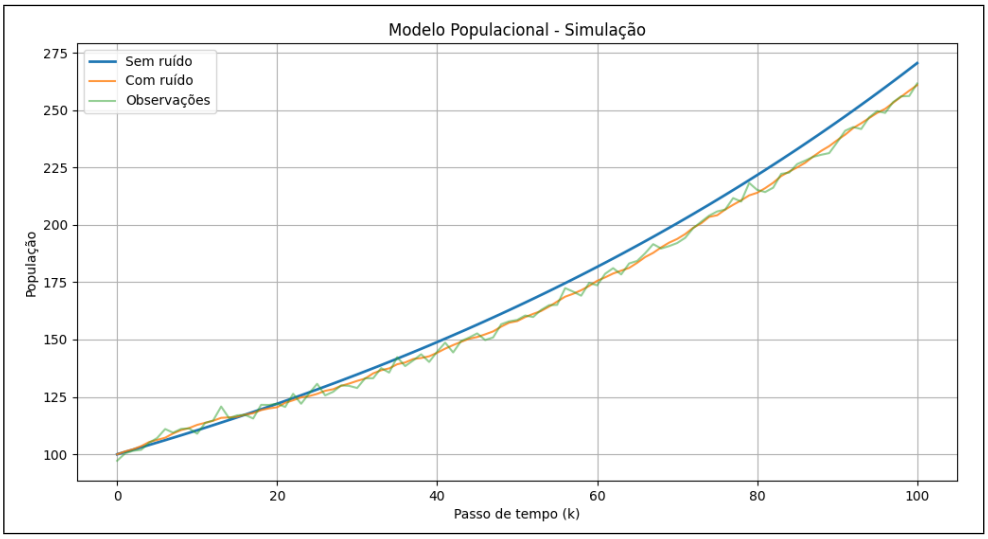

Figura 13: Simulação do modelo populacional, incluindo a trajetória determinística, o estado real com ruído de processo e as observações ruidosas.

Observa-se que a trajetória determinística apresenta crescimento suave, enquanto o estado real incorpora pequenas variações devido ao ruído de processo. As observações, por sua vez, apresentam oscilações adicionais decorrentes do ruído de medição, evidenciando a necessidade de técnicas de estimação para recuperação do estado real do sistema. Para quantificar o impacto desses ruídos, utilizou-se o erro quadrático médio normalizado (NRMSE), considerando 1000 realizações independentes do sistema.

Para o ruído de processo, obteve-se:

$$\overline{\mathrm{NRMSE}}_{\mathrm{proc}} = 0.026834 \tag{42}$$

Esse resultado indica que o ruído de processo introduz desvios na própria dinâmica do sistema, afetando a evolução do estado ao longo do tempo.

Para o ruído de observação, obteve-se:

$$\overline{\mathrm{NRMSE}}_{\mathrm{obs}} = 0.011618 \tag{43}$$

Esse valor menor indica que o ruído de medição introduz perturbações locais nas observações, com impacto inferior ao ruído de processo.

A comparação entre os dois resultados evidencia que, nesta configuração, o ruído de processo constitui a principal fonte de incerteza do sistema, enquanto o ruído de observação possui impacto mais limitado.

Aplicação do Filtro de Kalman

Para a estimação do estado do sistema, foram consideradas três formulações do filtro de Kalman: a estimativa filtrada, a estimativa preditiva e a formulação completa preditivo-corretiva. Cada uma delas enfatiza diferentes aspectos do algoritmo e permite analisar o impacto das etapas de predição e correção no desempenho da estimação.

Para fins de ilustração, as Figuras 14, 15 e 16 apresentam uma realização do sistema considerando `seed` = 42.

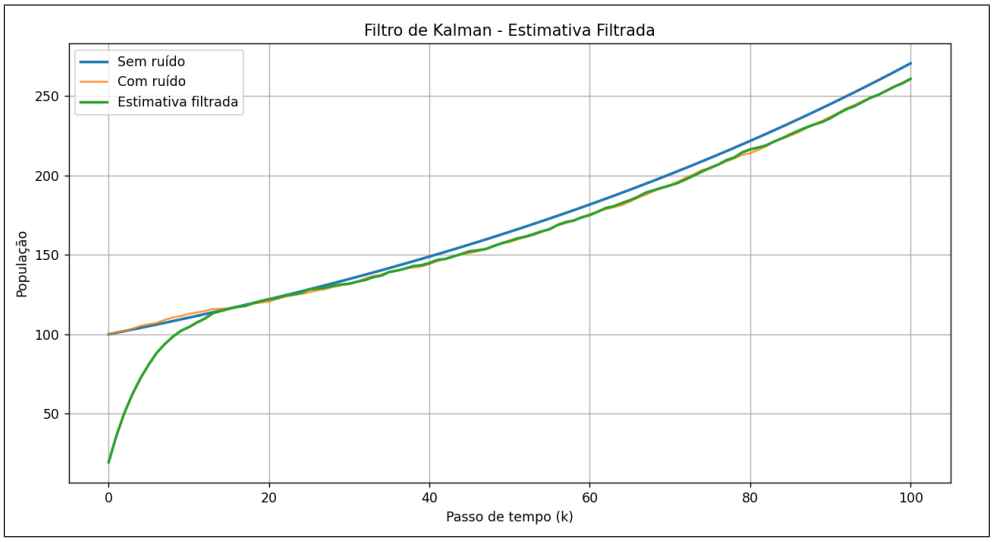

Figura 14: Estimativa filtrada do filtro de Kalman.

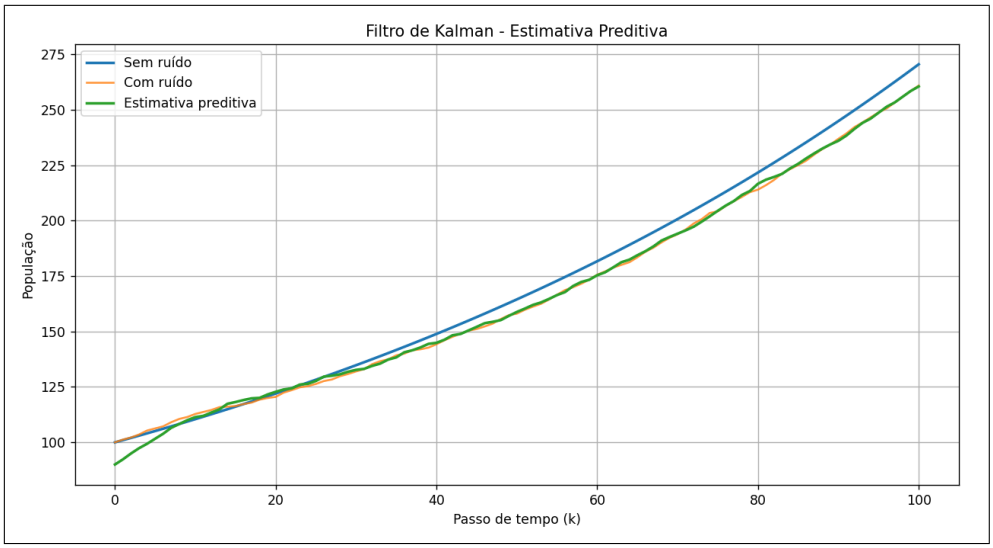

Figura 15: Estimativa preditiva do filtro de Kalman.

A partir das figuras, observa-se que a estimativa filtrada apresenta um desvio significativo nos instantes iniciais, decorrente da forma de inicialização adotada. Como a estimativa inicial é obtida a partir de uma combinação ponderada da medição e da matriz

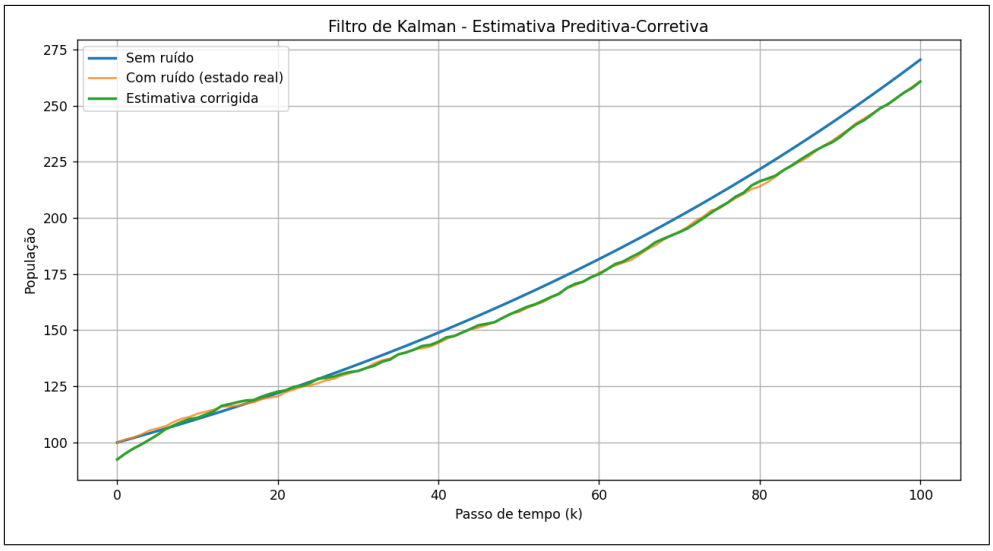

Figura 16: Estimativa preditivo-corretiva do filtro de Kalman.

de covariância, e considerando a elevada variância do ruído de observação, a influência da medição inicial é reduzida. Isso resulta em uma estimativa inicial pouco representativa do estado real, sendo progressivamente corrigida ao longo do tempo.

Já a estimativa preditiva apresenta comportamento mais estável desde o início, acompanhando de forma consistente a trajetória do sistema. No entanto, por não incorporar explicitamente a etapa de correção no instante corrente, pequenas discrepâncias ainda podem ser observadas ao longo da evolução.

Por fim, a formulação preditivo-corretiva combina explicitamente as etapas de predição e correção, apresentando o melhor desempenho entre as abordagens analisadas. Observa-se que essa estimativa acompanha de forma mais precisa o estado real, capturando tanto a tendência global quanto as variações locais do sistema.

Do ponto de vista quantitativo, o desempenho foi avaliado por meio do NRMSE, considerando 1000 realizações independentes. Foram obtidos os seguintes resultados:

$$\overline{\text{NRMSE}}_{\text{filtrada}} = 0.076034 \quad (\sigma = 0.001923) \tag{44}$$

$$\overline{\text{NRMSE}}_{\text{preditiva}} = 0.011425 \quad (\sigma = 0.000753) \tag{45}$$

$$\overline{\text{NRMSE}}_{\text{pred-corr}} = 0.008355 \quad (\sigma = 0.000761) \tag{46}$$

Comparando os resultados, observa-se que a estimativa preditiva apresenta uma redução de aproximadamente:

$$\frac{0.076034 - 0.011425}{0.076034} \approx 85.0\%$$

em relação à estimativa filtrada.

Já a formulação preditivo-corretiva apresenta uma redução ainda maior:

$$\frac{0.076034 - 0.008355}{0.076034} \approx 89.0\%$$

em relação à estimativa filtrada.

Além disso, ao comparar diretamente a estimativa preditiva com a preditivo-corretiva, observa-se uma melhoria adicional de aproximadamente:

$$\frac{0.011425 - 0.008355}{0.011425} \approx 26.9\%$$

evidenciando o impacto da etapa de correção na redução do erro.

Esses resultados demonstram que a estimativa filtrada é fortemente influenciada pelas condições iniciais, podendo apresentar desempenho inferior quando a inicialização não é consistente com o estado real do sistema. Por outro lado, observa-se que a estimativa preditiva apresenta desempenho muito próximo ao das observações, o que está associado à escolha de um estado inicial próximo ao valor real, reduzindo o erro inicial e, consequentemente, limitando o ganho obtido pelo filtro.

Em contraste, a incorporação explícita das etapas de predição e correção na formulação preditivo-corretiva permite explorar de forma mais eficiente as informações disponíveis, resultando em uma redução mais significativa do erro. Dessa forma, essa abordagem apresenta o melhor desempenho dentre as analisadas, evidenciando a importância da atualização recursiva do estado com base nas medições ao longo do tempo.

Conclusão

Neste trabalho, foi abordado o problema de estimação de estados em sistemas dinâmicos sujeitos a incertezas, considerando tanto a presença de ruído de processo quanto de ruído de observação. Inicialmente, foi analisado um modelo estocástico para a evolução de preços, permitindo compreender como diferentes fontes de incerteza afetam a dinâmica do sistema.

A análise do ruído de processo evidenciou seu caráter acumulativo, gerando desvios progressivos em relação à trajetória determinística, enquanto o ruído de observação apresentou comportamento local, sem impacto direto na evolução do estado. A utilização do NRMSE permitiu quantificar esses efeitos, mostrando que o ruído de processo tende a exercer maior influência na dinâmica do sistema ao longo do tempo.

A partir dessa modelagem, foi aplicado o filtro de Kalman, com destaque para a formulação preditivo-corretiva. Os resultados obtidos demonstraram que o algoritmo é capaz de combinar de forma eficiente as informações do modelo dinâmico e das medições, produzindo estimativas bastante próximas do estado real do sistema.

Do ponto de vista quantitativo, observou-se uma redução significativa no erro de estimação em relação às medições. No modelo de preços, essa redução foi da ordem de 92%, evidenciando a forte capacidade do filtro em atenuar o ruído de observação. Além disso, verificou-se que a etapa de correção desempenha papel fundamental na melhoria da estimativa, ajustando continuamente a predição com base nas informações disponíveis.

Na segunda parte do trabalho, foi considerado um modelo populacional do tipo Malthus-Verhulst, no qual também foram introduzidos ruídos de processo e de observação. A análise mostrou que, nessa configuração, o ruído de processo constitui a principal fonte de incerteza do sistema, enquanto o ruído de observação apresenta impacto mais limitado.

A aplicação do filtro de Kalman ao modelo populacional confirmou novamente sua eficácia, apresentando uma redução de aproximadamente 52% no erro de estimação em relação às medições. Esse resultado indica que, mesmo em um cenário com dinâmica distinta, o filtro mantém sua capacidade de melhorar significativamente a estimativa do estado.

Adicionalmente, verificou-se que as formulações filtrada e preditivo-corretiva são matematicamente equivalentes, diferindo apenas na forma de apresentação. Enquanto a formulação preditiva-corretiva explicita as etapas de predição e correção, a forma filtrada

apresenta diretamente a estimativa final. Em ambos os casos, o resultado obtido corresponde à mesma estimativa do estado, isto é, $\hat{x}_{k|k}$.

De forma geral, os resultados obtidos ao longo do trabalho evidenciam que o filtro de Kalman constitui uma ferramenta robusta e eficiente para a estimação de estados em sistemas dinâmicos, sendo particularmente adequado em cenários nos quais há incertezas tanto na dinâmica quanto nas observações. Sua capacidade de equilibrar essas duas fontes de informação permite obter estimativas consistentes e confiáveis em diferentes contextos de modelagem.