



UNIVERSIDADE ESTADUAL DE SANTA CRUZ

Mestrado em Modelagem Computacional

Projeto 3

TEORIA DA ESTIMAÇÃO

Professor: Gildson Queiroz de Jesus

Aluno: João Vitor Nascimento Ramos

Ilhéus – BA
Maio 2026

Introdução

A estimação de parâmetros em sistemas dinâmicos constitui um problema relevante em áreas como engenharia e modelagem matemática, especialmente em situações nas quais os parâmetros do sistema não são conhecidos exatamente e precisam ser obtidos a partir de dados observados. Em problemas não lineares, essa estimação pode apresentar dificuldades numéricas e forte correlação entre parâmetros, tornando necessária a utilização de métodos iterativos de mínimos quadrados. Nesse contexto, destacam-se os métodos de Gauss-Newton e Levenberg-Marquardt, amplamente utilizados na estimação de parâmetros em modelos não lineares. Enquanto o método de Gauss-Newton utiliza uma aproximação linear local baseada na matriz Jacobiana, o método de Levenberg-Marquardt introduz um fator de amortecimento para melhorar a estabilidade numérica e reduzir problemas de divergência.

Neste trabalho, são analisadas as abordagens de Gauss-Newton, Levenberg-Marquardt com amortecimento fixo e Levenberg-Marquardt adaptativo aplicadas à estimação de parâmetros em um modelo dinâmico de propagação de informação. Os métodos são comparados a partir das estimativas obtidas, do erro residual e do comportamento iterativo dos algoritmos.

Modelo de Propagação de Informação

Neste trabalho, considera-se um modelo matemático discreto para descrever a propagação de informação em uma população. A formulação utilizada é inspirada em modelos epidemiológicos do tipo SIR (*Susceptible-Infected-Recovered*), amplamente empregados para representar dinâmicas de disseminação, mas adaptada ao contexto de transmissão de informação entre indivíduos. Nesse modelo, a população é dividida em três grupos distintos: os indivíduos **ignorantes** (*Ignorants*), representados por I_i , que ainda não tiveram contato com a informação, os indivíduos **espalhadores** (*Spreaders*), representados por S_i , que conhecem a informação e a propagam para outros indivíduos, e os indivíduos **sufocadores** (*Stiflers*), representados por R_i , que já tiveram contato com a informação, mas deixaram de propagá-la, seja por perda de interesse, saturação ou refutação. A evolução temporal dessas populações é descrita pelo seguinte sistema de equações em tempo discreto:

$$I_{i+1} = I_i - \beta k S_i I_i \quad (1)$$

$$S_{i+1} = S_i + \beta k S_i I_i - \alpha S_i (S_i + R_i) \quad (2)$$

$$R_{i+1} = R_i + \alpha S_i (S_i + R_i) \quad (3)$$

em que:

- β representa a taxa de transmissão da informação;
- α representa a taxa de transição dos espalhadores para sufocadores;
- k representa a intensidade média de interação entre os indivíduos.

No modelo adotado, a transição de indivíduos espalhadores para o estado de sufocação ocorre a partir da interação com indivíduos que já tiveram contato com a informação, sejam eles outros espalhadores ou sufocadores. Esse comportamento é representado pelo termo $\alpha S_i (S_i + R_i)$. A interpretação social desse mecanismo está associada ao fenômeno de saturação informacional. Quando um indivíduo que está propagando uma determinada

informação passa a interagir repetidamente com pessoas que já conhecem aquele conteúdo, a tendência de continuar disseminando essa informação diminui. Isso pode ocorrer por diferentes motivos, como perda de novidade, redução do interesse coletivo, percepção de que a informação já se tornou amplamente conhecida ou até mesmo pela contestação por parte de outros indivíduos. Dessa forma, o encontro entre indivíduos informados reduz gradualmente a capacidade de propagação do sistema, favorecendo o crescimento da população de sufocadores e conduzindo naturalmente a dinâmica para um regime de estabilização.




Figura 1: Representação esquemática do modelo discreto de propagação de informação.

Parâmetros Utilizados na Simulação

Com o objetivo de analisar numericamente a dinâmica de propagação de informação descrita pelo modelo proposto, foi realizada uma simulação em tempo discreto considerando uma população normalizada, isto é, mantendo constante a soma das proporções dos indivíduos ao longo da evolução do sistema. Na simulação, foram adotados os valores $\beta = 0.04$, $\alpha = 0.03$ e $k = 0.8$, definindo um cenário com propagação moderada da informação e saturação gradual do processo de disseminação. As condições iniciais utilizadas foram $I_0 = 0.9$, $S_0 = 0.1$ e $R_0 = 0.0$. Esse cenário representa uma situação em que a maior parte da população ainda não teve contato com a informação, enquanto uma pequena parcela atua inicialmente como agente disseminador. Além disso, inicialmente não existem indivíduos no estado de sufocação, permitindo observar de forma mais clara o surgimento natural desse grupo ao longo da dinâmica do sistema. A simulação foi executada durante $N = 500$ passos discretos, número suficiente para acompanhar desde a fase inicial de propagação da informação até a redução gradual da atividade de disseminação e a aproximação do sistema a um regime de estabilização.

Resultado da Simulação do Modelo

A partir dos parâmetros definidos anteriormente, foi realizada a simulação do modelo. A Figura 2 apresenta a evolução temporal das populações de indivíduos ignorantes, espalhadores e sufocadores.




Figura 2: Evolução temporal das populações de ignorantes, espalhadores e sufocadores no modelo de propagação de informação.

Inicialmente, a elevada quantidade de indivíduos ignorantes favorece a disseminação da informação, uma vez que existe uma grande parcela da população ainda disponível para ser alcançada pelos espalhadores. Como consequência, nas primeiras iterações a população de espalhadores cresce progressivamente, atingindo aproximadamente 0.32 por volta da iteração 80. Esse ponto representa o instante de maior circulação da informação na população. Até esse momento, o crescimento da população de espalhadores ocorre porque o termo de transmissão $\beta k S_i I_i$ permanece suficientemente elevado, impulsionado pela interação entre indivíduos ignorantes e indivíduos espalhadores. Entretanto, à medida que a informação se propaga, o número de indivíduos ignorantes começa a diminuir gradualmente, reduzindo a disponibilidade de novos indivíduos para receber a informação pela primeira vez.

Após o pico de disseminação, a população de espalhadores passa a decrescer progressivamente. Por volta da iteração 100, a população de ignorantes já foi reduzida para aproximadamente 0.40, enquanto a população de sufocadores cresce para cerca de 0.27. Isso indica que uma parcela significativa da população já teve contato com a informação, alterando gradualmente a dinâmica do sistema. Entre as iterações 100 e 200, observa-se uma mudança importante no comportamento do modelo. A população de sufocadores

ultrapassa a população de ignorantes e passa a se tornar dominante. Aproximadamente na iteração 200, os ignorantes representam cerca de 0.21 da população, os espalhadores cerca de 0.08 e os sufocadores aproximadamente 0.70. Nesse estágio, a propagação ativa da informação já perdeu intensidade, pois os encontros entre indivíduos que já conhecem o conteúdo tornam-se mais frequentes.

Esse comportamento está diretamente relacionado ao termo $\alpha S_i(S_i + R_i)$, responsável pela transição de espalhadores para sufocadores. Do ponto de vista social, esse termo representa um processo de **saturação informacional**. À medida que mais indivíduos passam a conhecer a informação, aumenta a probabilidade de um espalhador interagir com pessoas que já tiveram contato com o conteúdo. Como consequência, a informação perde novidade, o interesse em propagá-la diminui e podem surgir processos de contestação, correção ou simples desmotivação para continuar compartilhando.

Nas iterações finais, especialmente após aproximadamente 300 iterações, o sistema se aproxima de um regime estacionário. A população de espalhadores tende a valores próximos de zero, indicando que a disseminação ativa praticamente cessa. Ao final da simulação, observa-se uma população de ignorantes próxima de 0.18, uma população de espalhadores praticamente nula e uma população de sufocadores próxima de 0.82. Portanto, a simulação evidencia uma dinâmica típica de propagação com saturação. Inicialmente, a informação se espalha rapidamente, atingindo um pico de espalhadores em torno de 32% da população. Em seguida, a disseminação perde intensidade devido à redução dos ignorantes e ao crescimento dos sufocadores. Por fim, o sistema se estabiliza com predominância de indivíduos que já tiveram contato com a informação, mas não continuam a propagá-la.

Estimação de Parâmetros pelo Método de Gauss-Newton

O método de Gauss-Newton é uma técnica numérica iterativa utilizada na resolução de problemas de mínimos quadrados não lineares. Seu objetivo é ajustar os parâmetros de um modelo matemático de modo que a resposta produzida pelo modelo se aproxime, o máximo possível, de um conjunto de dados observados. No contexto deste trabalho, o método foi aplicado ao modelo de propagação de informação com o objetivo de estimar os parâmetros β , α e k a partir das trajetórias observadas das populações de ignorantes, espalhadores e sufocadores obtidas na simulação do sistema. Dessa forma, define-se o seguinte vetor de parâmetros desconhecidos:

$$\theta = \begin{bmatrix} \beta \\ \alpha \\ k \end{bmatrix} \quad (4)$$

Para cada escolha de θ , o modelo gera uma trajetória simulada para as variáveis I_i , S_i e R_i . Essa trajetória é comparada com os dados observados por meio do vetor de resíduos, definido por:

$$r(\theta) = y_{\text{obs}} - y_{\text{mod}}(\theta) \quad (5)$$

em que y_{obs} representa os dados observados e $y_{\text{mod}}(\theta)$ representa a resposta do modelo associada ao vetor de parâmetros θ . O problema de estimação é então formulado como um problema de minimização da soma dos quadrados dos resíduos:

$$\min_{\theta} \frac{1}{2} \|r(\theta)\|^2 \quad (6)$$

Como o problema é não linear em relação aos parâmetros, o método de Gauss-Newton realiza uma linearização local do vetor de resíduos em torno da estimativa atual, isto é,

$$r(\theta_j + \Delta\theta) \approx r(\theta_j) + J(\theta_j)\Delta\theta \quad (7)$$

em que $J(\theta_j)$ é a matriz Jacobiana dos resíduos em relação aos parâmetros. A partir

dessa aproximação, a correção $\Delta\theta$ é obtida resolvendo-se o sistema normal

$$J^T J \Delta\theta = J^T r \quad (8)$$

Uma vez calculada a correção, os parâmetros são atualizados por

$$\theta_{j+1} = \theta_j - \Delta\theta \quad (9)$$

Esse processo é repetido até que o método satisfaça um critério de parada, como a redução suficiente da norma do erro ou da variação dos parâmetros entre duas iterações consecutivas.

Aplicação do Método

Na aplicação do método de Gauss-Newton ao modelo de propagação de informação, foram utilizados como valores iniciais

$$\beta_0 = 0.03 \quad \alpha_0 = 0.02 \quad k_0 = 1.0$$

os quais são relativamente próximos dos valores reais do modelo,

$$\beta = 0.04 \quad \alpha = 0.03 \quad k = 0.8.$$

Além disso, o processo iterativo foi executado com tolerância 10^{-8} e $\epsilon = 10^{-6}$ para o cálculo numérico da matriz Jacobiana. Ao final de 11 iterações, o método produziu as seguintes estimativas:

$$\hat{\beta} = 55.037976 \quad \hat{\alpha} = 0.030000 \quad \hat{k} = 0.000581.$$

Comparando com os valores reais utilizados na geração dos dados observados, verifica-se novamente que o método recuperou corretamente o parâmetro α , mas não foi capaz de estimar adequadamente os parâmetros β e k individualmente. Mesmo partindo de valores iniciais relativamente próximos dos parâmetros reais, o método fez com que β convergisse para um valor extremamente elevado, enquanto k foi reduzido para um valor muito próximo de zero. Esse resultado evidencia que a dificuldade do método não está associada apenas à escolha de um chute inicial inadequado. A limitação observada está relacionada principalmente à própria estrutura do modelo matemático.

De fato, no modelo de propagação de informação, os parâmetros β e k aparecem sempre de forma acoplada no termo de transmissão $\beta k S_i I_i$, responsável pela propagação da informação entre indivíduos ignorantes e espalhadores. Assim, a dinâmica do sistema depende diretamente do produto βk , e não necessariamente dos valores individuais de β e k . Para os valores reais utilizados na simulação, tem-se:

$$\beta k = 0.04 \cdot 0.8 = 0.032.$$

Já com os valores estimados pelo método de Gauss-Newton, obtém-se aproximadamente:

$$\hat{\beta}\hat{k} \approx 55.037976 \cdot 0.000581 \approx 0.0320.$$

Portanto, embora os valores individuais estimados para $\hat{\beta}$ e $\hat{k}$ não sejam fisicamente interpretáveis, o produto entre eles permanece extremamente próximo do valor real utilizado na simulação. Isso mostra que o método foi capaz de reproduzir corretamente o efeito combinado de transmissão da informação, mas não conseguiu separar adequadamente a contribuição individual de cada parâmetro. A Figura 3 apresenta simultaneamente a evolução da norma do incremento iterativo $\|\Delta\theta\|$ e da convergência dos parâmetros β , α e k ao longo das iterações do método de Gauss-Newton.




Figura 3: Convergência do incremento iterativo e dos parâmetros estimados no método de Gauss-Newton.

Observa-se inicialmente que a norma do incremento iterativo $\|\Delta\theta\|$ apresenta valores extremamente elevados nas primeiras iterações, especialmente na etapa inicial do método. Isso indica que o algoritmo realizou atualizações muito agressivas no espaço de parâmetros, provocando grandes deslocamentos da solução ao longo do processo iterativo.

Entretanto, após essas oscilações iniciais, a norma de $\Delta\theta$ passa a diminuir progressivamente, atingindo valores próximos de 10^{-8} nas iterações finais. Esse comportamento mostra que o método convergiu numericamente segundo o critério de tolerância adotado. A evolução do parâmetro β mostra um crescimento abrupto logo nas primeiras iterações,

estabilizando-se rapidamente em valores muito superiores ao valor real utilizado na simulação. Em contrapartida, o parâmetro k sofre uma queda igualmente abrupta, tornando-se praticamente nulo já nas primeiras iterações. Esse comportamento complementar evidencia claramente o problema de identificabilidade estrutural presente no modelo.

Diferentemente do observado para β e k , o parâmetro α apresentou apenas oscilações moderadas durante as primeiras iterações, convergindo progressivamente para o valor real $\alpha = 0.03$. Esse resultado é coerente com a estrutura do modelo, uma vez que α aparece de forma mais isolada no termo

$$\alpha S_i(S_i + R_i),$$

o que torna sua influência na dinâmica do sistema mais facilmente identificável.

Portanto, os resultados obtidos mostram que o método de Gauss-Newton foi capaz de reproduzir adequadamente a dinâmica global observada. Entretanto, devido ao forte acoplamento estrutural entre os parâmetros β e k , o método não conseguiu recuperar corretamente os valores individuais desses parâmetros, evidenciando limitações importantes de identificabilidade no problema considerado.

Por fim, a Figura 4 apresenta a simulação do modelo utilizando os parâmetros estimados pelo método de Gauss-Newton.




Figura 4: Trajetórias do modelo de propagação de informação simuladas com os parâmetros estimados pelo método de Gauss-Newton.

Observa-se que, apesar das estimativas individuais de β e k apresentarem valores significativamente diferentes dos parâmetros reais, a dinâmica simulada preserva adequadamente o comportamento global do sistema. A população de ignorantes decresce ao

longo do tempo, a população de espalhadores apresenta um crescimento inicial seguido de decaimento, enquanto a população de sufocadores cresce progressivamente até se tornar dominante. Esse comportamento ocorre porque os parâmetros β e k aparecem acoplados no termo de transmissão $\beta k S_i I_i$. Assim, embora o método não tenha recuperado corretamente os valores individuais desses parâmetros, o produto $\hat{\beta}\hat{k}$ permaneceu muito próximo do valor real βk , permitindo reproduzir adequadamente a dinâmica observada.

Conclusão da Aplicação do Método

Os resultados obtidos mostram que o método de Gauss-Newton foi capaz de reproduzir adequadamente a dinâmica global do modelo de propagação de informação. Entretanto, a análise das estimativas evidencia limitações importantes na identificação individual dos parâmetros do sistema.

O parâmetro α foi estimado corretamente ao longo do processo iterativo, enquanto os parâmetros β e k convergiram para valores significativamente diferentes dos utilizados na geração dos dados observados. Esse comportamento persistiu mesmo utilizando valores iniciais relativamente próximos dos parâmetros reais, indicando que a principal dificuldade do problema não está associada apenas ao chute inicial.

A principal limitação observada está relacionada à estrutura matemática do modelo, uma vez que os parâmetros β e k aparecem sempre acoplados no termo de transmissão da informação. Dessa forma, diferentes combinações desses parâmetros podem produzir trajetórias muito semelhantes, dificultando sua identificação individual.

Conclui-se, portanto, que o método de Gauss-Newton mostrou-se eficiente na reprodução da dinâmica global do sistema, mas apresentou limitações importantes em problemas com forte correlação estrutural entre parâmetros. Essa limitação motiva a utilização de métodos mais robustos e numericamente estáveis, como o método de Levenberg-Marquardt, analisado no capítulo seguinte.

Estimação de Parâmetros pelo Método de Levenberg-Marquardt

O método de Levenberg-Marquardt pode ser interpretado como uma modificação do método de Gauss-Newton, incorporando um termo de amortecimento responsável por aumentar a estabilidade numérica do processo iterativo em problemas não lineares mal condicionados ou com forte correlação entre parâmetros. Neste trabalho, o método foi aplicado ao problema de estimação dos parâmetros β , α e k do modelo de propagação de informação, considerando a mesma formulação de mínimos quadrados apresentada anteriormente para o método de Gauss-Newton. Diferentemente do método de Gauss-Newton, a correção dos parâmetros é obtida por meio da resolução do sistema regularizado

$$(J^T J + \mu I) \Delta \theta = J^T r \quad (10)$$

em que J representa a matriz Jacobiana dos resíduos em relação aos parâmetros, μ é o fator de amortecimento e I é a matriz identidade. O valor inicial do fator de amortecimento é estimado automaticamente a partir dos elementos diagonais da matriz

$$A_k = J_k^T J_k \quad (11)$$

calculada na primeira iteração do algoritmo. Para isso, utiliza-se a relação

$$\mu_0 = \tau \max \{a_{ii}^{(0)}\} \quad (12)$$

em que τ representa uma constante positiva de escala e $a_{ii}^{(0)}$ correspondem aos elementos da diagonal principal da matriz A_0 .

O termo μI atua como uma regularização da matriz $J^T J$, reduzindo a sensibilidade do método a problemas de mau condicionamento numérico. Quando o valor de μ é pequeno, o método se aproxima do comportamento do Gauss-Newton. Por outro lado, quando μ assume valores elevados, o algoritmo realiza atualizações mais conservadoras, aproximando-se do comportamento de métodos de descida do gradiente.

Após o cálculo da correção $\Delta \theta$, os parâmetros são atualizados por meio da relação

$$\theta_{j+1} = \theta_j - \Delta\theta \quad (13)$$

Entretanto, diferentemente da abordagem com amortecimento fixo, neste trabalho foi utilizada uma estratégia de amortecimento adaptativo, na qual o valor de μ é atualizado dinamicamente ao longo das iterações conforme a qualidade do passo realizado pelo algoritmo. Para medir a qualidade do passo iterativo, foi utilizado o parâmetro

$$\xi = \frac{\text{redução real}}{\text{redução prevista}} = \frac{f(\theta_k) - f(\theta_{k+1})}{f(\theta_k) - \hat{f}(\theta_{k+1})} \quad (14)$$

em que $f(\theta_k) - f(\theta_{k+1})$ representa a redução real da função custo e $f(\theta_k) - \hat{f}(\theta_{k+1})$ corresponde à redução prevista pelo modelo linear local utilizado na iteração. Dessa forma, o parâmetro ξ mede o quanto a redução observada na função custo se aproxima da redução prevista pelo modelo linearizado. Quando ξ assume valores positivos, significa que o passo realizado produziu redução efetiva da função custo, sendo então aceito pelo algoritmo. A atualização do fator de amortecimento foi realizada segundo a regra

$$\mu_{k+1} = \begin{cases} 2\mu_k, & \text{se } \xi < 0.25 \\ \frac{\mu_k}{3}, & \text{se } \xi > 0.75 \\ \mu_k, & \text{se } 0.25 \leq \xi \leq 0.75 \end{cases} \quad (15)$$

Quando $\xi < 0.25$, o passo realizado apresenta baixa qualidade de aproximação, exigindo maior amortecimento e maior estabilidade numérica. Por outro lado, quando $\xi > 0.75$, o passo é considerado de boa qualidade, permitindo reduzir o amortecimento e realizar atualizações mais agressivas. Já para valores intermediários de ξ , o fator de amortecimento é mantido inalterado.

Essa estratégia permite ajustar automaticamente o equilíbrio entre **estabilidade numérica** e **velocidade de convergência** ao longo das iterações. Quando o modelo linear local representa adequadamente a função custo, o método reduz o amortecimento e aproxima-se do comportamento do Gauss-Newton. Por outro lado, quando a aproximação linear apresenta baixa qualidade, o aumento de μ torna o algoritmo mais conservador e estável. Dessa forma, o amortecimento adaptativo reduz significativamente a dependência da escolha manual de um valor fixo de μ , tornando o método mais robusto em problemas não lineares fortemente correlacionados, como o presente modelo de propagação de informação, no qual os parâmetros β e k aparecem estruturalmente acoplados no termo de transmissão $\beta k S_i I_i$.

Análise dos Resultados

Mantendo os mesmos parâmetros reais utilizados na aplicação anterior, foi aplicado o método de Levenberg-Marquardt com amortecimento adaptativo ao problema de estimação dos parâmetros do modelo de propagação de informação. Para esta análise, adotou-se o seguinte vetor inicial de estimação:

$$\theta_0 = [\beta_0, \alpha_0, k_0] = [0.030, 0.020, 1.0] \quad (16)$$

Mesmo utilizando um vetor inicial relativamente simples e ainda distante dos valores reais do sistema, o método apresentou comportamento numericamente estável e rápida convergência. Ao final do processo iterativo, a solução foi obtida em apenas 5 iterações, produzindo as seguintes estimativas:

$$\hat{\beta} = 0.031998, \quad \hat{\alpha} = 0.030000, \quad \hat{k} = 1.000061 \quad (17)$$

Além disso, o fator de amortecimento foi inicializado automaticamente com $\mu_0 = 1.372823 \times 10^2$ e evoluiu dinamicamente até atingir o valor final $\mu = 5.084531$. Esse comportamento está relacionado à escala numérica da matriz $J^T J$ calculada nas primeiras iterações. Como a Jacobiana foi construída utilizando toda a trajetória temporal do sistema, os elementos de $J^T J$ assumiram valores relativamente elevados, produzindo um valor inicial elevado para μ . Dessa forma, o algoritmo iniciou o processo iterativo de maneira mais conservadora e numericamente estável, reduzindo a sensibilidade às fortes correlações existentes entre os parâmetros β e k .

A Figura 5 apresenta a evolução do fator de amortecimento ao longo das iterações.




Figura 5: Evolução do fator de amortecimento μ no método de Levenberg-Marquardt.

Observa-se que o fator de amortecimento inicia com um valor elevado e decresce progressivamente ao longo das iterações. Isso indica que, nas etapas iniciais, o método priorizou estabilidade numérica, realizando atualizações mais conservadoras. À medida que o algoritmo se aproximou da solução, o valor de μ foi reduzido automaticamente, fazendo o método aproximar-se gradualmente do comportamento do método de Gauss-Newton e acelerando a convergência.

A Figura 6 apresenta a evolução da norma de $\Delta\theta$ e dos parâmetros estimados ao longo das iterações.




Figura 6: Convergência da norma de $\Delta\theta$ e evolução iterativa dos parâmetros estimados pelo método de Levenberg-Marquardt.

Observa-se que a norma de $\Delta\theta$ decresce rapidamente ao longo das iterações, atingindo valores próximos de 10^{-10} nas etapas finais do algoritmo. Esse comportamento indica convergência numérica segundo o critério de tolerância adotado e evidencia a elevada estabilidade do processo iterativo. Diferentemente do comportamento observado anteriormente no método de Gauss-Newton, a evolução dos parâmetros ocorreu de forma suave e controlada, sem oscilações bruscas ou deslocamentos para valores numericamente extremos.

Observa-se que o parâmetro α convergiu corretamente para o valor real do sistema, estabilizando em $\hat{\alpha} = 0.030000$. Já os parâmetros β e k não foram recuperados individualmente de forma exata. Entretanto, o produto responsável pela dinâmica de transmissão da informação permaneceu praticamente idêntico ao valor real do sistema, isto é, $\hat{\beta}\hat{k} = 0.032000$.

Esse resultado mostra que o método foi capaz de preservar corretamente o efeito global de transmissão da informação, mesmo diante da forte correlação estrutural existente entre

os parâmetros β e k . Embora esses parâmetros não tenham sido recuperados individualmente de forma exata, as estimativas obtidas permaneceram numericamente estáveis e fisicamente coerentes, diferentemente do comportamento observado no método de Gauss-Newton.

Comparativamente ao método anterior, observa-se uma melhora significativa tanto em estabilidade numérica quanto em interpretabilidade física da solução obtida. Enquanto o método de Gauss-Newton convergiu para valores extremos de β e k , o método de Levenberg-Marquardt produziu estimativas mais consistentes, mantendo corretamente a intensidade global de transmissão representada pelo produto βk . Dessa forma, os resultados obtidos evidenciam que a estratégia de amortecimento utilizada foi fundamental para aumentar a robustez do processo iterativo, permitindo controlar automaticamente o equilíbrio entre estabilidade e velocidade de convergência ao longo das iterações.

Comparação Quantitativa entre os Métodos

Além da análise qualitativa das trajetórias estimadas e da evolução iterativa dos parâmetros, torna-se importante comparar quantitativamente o desempenho dos métodos utilizados. Para isso, foi utilizado o erro relativo percentual entre o valor real de cada parâmetro e o valor estimado pelo algoritmo, definido por:

$$\text{Erro Relativo}(\%) = \frac{|\theta_{real} - \theta_{estimado}|}{|\theta_{real}|} \times 100 \quad (18)$$

em que θ representa qualquer parâmetro do modelo, isto é, β , α ou k .

Além da precisão das estimativas, também foi analisada a quantidade de iterações necessária para convergência de cada método, permitindo avaliar simultaneamente a estabilidade numérica e a eficiência computacional dos algoritmos.

A Tabela 1 apresenta os erros relativos obtidos para os métodos de Gauss-Newton e Levenberg-Marquardt, bem como o número de iterações necessárias para convergência.

Tabela 1: Comparação quantitativa entre os métodos de Gauss-Newton e Levenberg-Marquardt.

Parâmetro	Gauss-Newton	Levenberg-Marquardt
β	$1.375 \times 10^5\%$	20.01%
α	0.00%	0.00%
k	99.93%	25.01%
Iterações	11	4

Os resultados mostram quantitativamente a superioridade do método de Levenberg-Marquardt em termos de estabilidade numérica e coerência física das estimativas obtidas. Enquanto o método de Gauss-Newton apresentou erros extremamente elevados para os

parâmetros β e k , o método de Levenberg-Marquardt conseguiu manter estimativas muito mais estáveis e fisicamente interpretáveis.

Observa-se ainda que ambos os métodos foram capazes de estimar corretamente o parâmetro α , indicando que esse parâmetro possui boa identificabilidade dentro da estrutura do modelo. Por outro lado, os parâmetros β e k continuaram apresentando dificuldades de identificação individual devido à forte correlação estrutural existente entre eles no termo de transmissão $\beta k S_i I_i$.

Mesmo assim, o método de Levenberg-Marquardt apresentou uma melhora significativa em relação ao método de Gauss-Newton. Enquanto o Gauss-Newton convergiu para valores extremos e fisicamente inconsistentes dos parâmetros, o método de Levenberg-Marquardt produziu estimativas mais equilibradas, preservando corretamente o efeito global de transmissão da informação.

A Figura 7 apresenta uma comparação direta da evolução da norma de $\Delta\theta$ para ambos os métodos.




Figura 7: Comparação da convergência da norma de $\Delta\theta$ entre os métodos de Gauss-Newton e Levenberg-Marquardt.

Observa-se que o método de Levenberg-Marquardt apresentou uma redução muito mais rápida e estável da norma de $\Delta\theta$, atingindo valores próximos de 10^{-10} em apenas quatro iterações. Em contraste, o método de Gauss-Newton apresentou oscilações significativas nas primeiras iterações e necessitou de um número maior de passos para atingir níveis semelhantes de convergência.

Esse comportamento evidencia diretamente o efeito estabilizador do fator de amortecimento introduzido no método de Levenberg-Marquardt. Nas etapas iniciais do processo iterativo, o amortecimento reduz a agressividade das atualizações dos parâmetros, evitando oscilações excessivas e aumentando a robustez numérica do algoritmo. À medida que a solução é aproximada, o amortecimento é reduzido automaticamente, permitindo que o método acelere a convergência e se aproxime gradualmente do comportamento do

método de Gauss-Newton.

Do ponto de vista computacional, observa-se também uma redução significativa no número de iterações necessárias para convergência. Enquanto o método de Gauss-Newton necessitou de 11 iterações para estabilizar a solução, o método de Levenberg-Marquardt convergiu em apenas 4 iterações, representando uma redução aproximada de:

$$\frac{11 - 4}{11} \times 100 \approx 63.6\% \quad (19)$$

Esse resultado evidencia que a introdução do fator de amortecimento no método de Levenberg-Marquardt não apenas aumentou a estabilidade numérica do problema, mas também acelerou significativamente o processo iterativo, produzindo estimativas numericamente mais robustas e fisicamente mais coerentes.

Influência do Valor Inicial de μ

Com o objetivo de avaliar a sensibilidade do método de Levenberg-Marquardt em relação ao valor inicial do fator de amortecimento, foram realizados testes variando μ_0 em diferentes ordens de grandeza. Em cada caso, foram registrados o número de iterações necessárias para convergência, o valor final de μ e a norma final de $\Delta\theta$. Os resultados obtidos também foram comparados com o valor inicial estimado automaticamente pela estratégia

$$\mu_0 = \tau \max \left\{ a_{ii}^{(0)} \right\},$$

a qual produziu, para este problema, o valor aproximado $\mu_0 \approx 1.37 \times 10^2$.

A Figura 8 apresenta a relação entre o valor inicial de μ e o número de iterações, bem como a norma final de $\Delta\theta$.




Figura 8: Influência do valor inicial de μ no número de iterações e na norma final de $\Delta\theta$.

Observa-se que valores muito pequenos de μ_0 exigem um número maior de iterações,

pois o método se aproxima do comportamento do Gauss-Newton, tornando-se menos amortecido. Por outro lado, valores muito elevados de μ_0 também aumentam o número de iterações, uma vez que o algoritmo passa a realizar atualizações excessivamente conservadoras.

A faixa intermediária apresentou o melhor desempenho, com convergência em aproximadamente 5 iterações para uma ampla região de valores de μ_0 , aproximadamente entre 10^{-3} e 10^3 . Nota-se ainda que o valor estimado automaticamente para μ_0 encontra-se precisamente dentro dessa região de melhor desempenho, evidenciando que a estratégia utilizada para inicialização do fator de amortecimento produziu um valor adequado para o problema analisado.

Além disso, a norma final de $\Delta\theta$ permaneceu extremamente pequena em praticamente todos os testes, indicando que o método convergiu numericamente de forma adequada mesmo sob diferentes escolhas iniciais de amortecimento. Esses resultados mostram que o método de Levenberg-Marquardt apresenta elevada robustez em relação à escolha inicial de μ , embora exista uma faixa mais eficiente capaz de proporcionar simultaneamente maior estabilidade numérica e menor número de iterações.

Conclusão

Neste trabalho, foram estudados métodos iterativos de mínimos quadrados não lineares aplicados ao problema de estimação de parâmetros em um modelo de propagação de informação. O objetivo principal consistiu em estimar os parâmetros β , α e k a partir das trajetórias observadas das populações de ignorantes, espalhadores e sufocadores.

Os resultados obtidos com o método de Gauss-Newton mostraram que, embora o algoritmo tenha sido capaz de reproduzir adequadamente a dinâmica global do sistema, surgiram limitações importantes na identificação individual dos parâmetros. O método convergiu em 11 iterações, porém produziu estimativas extremamente distantes dos valores reais para β e k , obtendo erros relativos de aproximadamente $1.375 \times 10^5\%$ e 99.93% , respectivamente. Apesar disso, o produto $\hat{\beta}\hat{k}$ permaneceu próximo do valor real, indicando que o método conseguiu preservar o efeito global de transmissão da informação.

A análise estrutural do modelo mostrou que essa dificuldade está diretamente associada ao forte acoplamento entre os parâmetros β e k , uma vez que ambos aparecem apenas por meio do produto $\beta k S_i I_i$ no termo de transmissão da informação.

Posteriormente, foi aplicado o método de Levenberg-Marquardt com amortecimento adaptativo. Comparativamente ao método de Gauss-Newton, observou-se melhora significativa tanto em estabilidade numérica quanto em coerência física das estimativas obtidas. O método convergiu em apenas 4 iterações, produzindo estimativas fisicamente mais consistentes e reduzindo os erros relativos para aproximadamente 20.01% em β e 25.01% em k . Além disso, o produto $\hat{\beta}\hat{k}$ permaneceu praticamente idêntico ao valor real do sistema, preservando corretamente a dinâmica global de transmissão da informação.

Também foi realizada uma análise de sensibilidade em relação ao valor inicial do fator de amortecimento μ_0 . Os resultados mostraram que o método apresentou elevada robustez para diferentes ordens de grandeza de μ_0 , convergindo corretamente em praticamente todos os testes realizados.

De forma geral, os resultados obtidos mostram que o método de Levenberg-Marquardt apresentou desempenho significativamente superior ao método de Gauss-Newton para o problema estudado, principalmente devido à introdução do fator de amortecimento adaptativo, que permitiu controlar automaticamente o equilíbrio entre estabilidade numérica e velocidade de convergência ao longo das iterações.